REPUBLIQUE DU SENEGAL
Un Peuple - Un But - Une Foi

UNIVERSITE IBA DER THIAM DE THIES

UFR SCIENCE DE L'INGENIEUR

LICENCE 2 GEOMATIQUE

DEVOIR PROJET ANAYSE 3

Realisée par :

Astou GUETE

Sous la supervision de :

M.Almamy

Année Academique

2025/2026

2.Travail de mandé

I.Chargement de la base de donnée :

```
library(readxl)
library(ggplot2)
df = read_excel(file.choose())
View(df)
str(df)
summary(df)
```

1.calcul du taux de NA par variable + visualiser(Barplot

2.A.1 calculer le taux de NA et visualise barplot

```
is.na(df)
na_col=colSums(is.na(df))
taux_NA = colSums(is.na(df))/nrow(df) * 100
taux_NA
```

```
Obs_ID              Station             Localite
            0.000000             0.000000
0.000000
          Type_zone            Usage_sol    Risque
_inondation
            0.000000             0.000000
0.000000
               Date        Temperature_C         H
Humidite_pct
              0.000000            11.805556
11.805556
```

```
            Pluie_mm             Vent_mps
PM25_ugm3
          11.805556            11.805556
11.805556
             NO2_ppb             Bruit_dB
NDVI
          11.805556            11.805556      qual
ite      11.805556
  Perception_air_1a5       Gene_bruit_1a5
_capteur
          11.805556            11.805556
11.805556
     Brulage_dechets   Phase_intervention
Campagne
          11.805556            83.333333
0.000000
    Agent_collecteur       Numero_serie_capteur
Commentaire
            0.000000             0.000000
9.027778
```

d'apres les resultats obtenus à partir du calcul des taux de NA

nous constatons qu'il y'a bel et bien des donnes manquantes

au niveau de plusieurs variables

barplot

barplot(taux_NA,

main = " taux de valeurs

manquantes par variables",

ylab = " pourcentage de NA

(%)",

col = "lightgreen",

```
ylim = c(0,100))
names.arg = names(taux_NA)
```

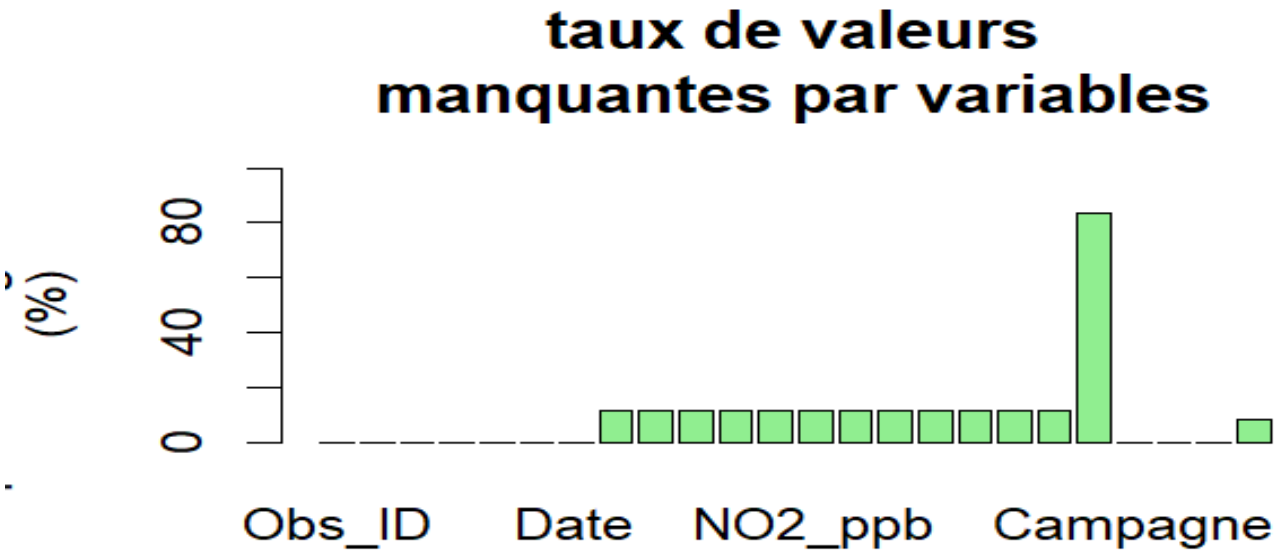

Commentaire du barplot

la barplot confirme la presence des donnes manquantes

2.A.2 traitement des données manquantes

pour les variables qualitatives

```
library(dplyr)
```

1.Identifier toutes les variables qualitatives (factor ou character)

```
vars_qual <- names(df)[sapply(df, function(x) is.factor(x) | is.character(x))]
```

2. Boucle pour remplacer les NA par la modalité la plus fréquente

```
for(v in vars_qual){
```

```
  mode_val <- names(sort(table(df[[v]]), decreasing = TRUE))[1]  # trouver le mode
  df[[v]][is.na(df[[v]])] <- mode_val                            # remplacer les NA
}
```

3. Vérification : nombre de NA restantes pour chaque variable qualitative

```
sapply(df[vars_qual], function(x) sum(is.na(x)))
```

Justification

Les valeurs manquantes des variables qualitatives ont
été remplacées par la modalité la plus fréquente afin de
conserver la distribution initiale des données.

```
pour les variables quantitatives
library(dplyr)
vars_quanti<- sapply(df, is.numeric)

df[vars_quanti] <- lapply(df[vars_quanti], function(x) {
  x[is.na(x)] <- median(x, na.rm = TRUE)
  return(x)
})
colSums(is.na(df))
#Justification
#Les valeurs manquantes des variables quantitatives ont été
#imputées par la médiane pour préserver la tendance centrale
#tout en limitant l’effet des valeurs extrêmes.
```

Obs_ID Station Localite

```
0            0                0
Type_zone          Usage_sol    Risque_inondation
0                0                    0
Date       Temperature_C        Humidite_pct
0                0                    0
Pluie_mm           Vent_mps          PM25_ugm3
0                0                      0
NO2_ppb           Bruit_dB              NDVI
0                0                       0
Perception_air_1a5      Gene_bruit_1a5      Qualite_capteur
0                0                              0
Brulage_dechets   Phase_intervention           Campagne
0                0                              0
Agent_collecteur   Numero_serie_capteur         Commentaire
0                0                              0
```

2.A.3. Détection des valeurs aberrantes(boxplot)

<u>PM25_ugm3</u>

```
x = df$PM25_ugm3
Q1 = quantile(x, 0.25, na.rm = TRUE)
Q3 = quantile(x, 0.75, na.rm = TRUE)
IQR = Q3 - Q1
borne_inf = Q1 - 1.5 * IQR
borne_sup = Q3 + 1.5 * IQR
outliers = x[x < borne_inf | x > borne_sup]
outliers
boxplot(df$PM25_ugm3, main = "Visualisation des valeurs aberrante pour PM25_ugm3")
```

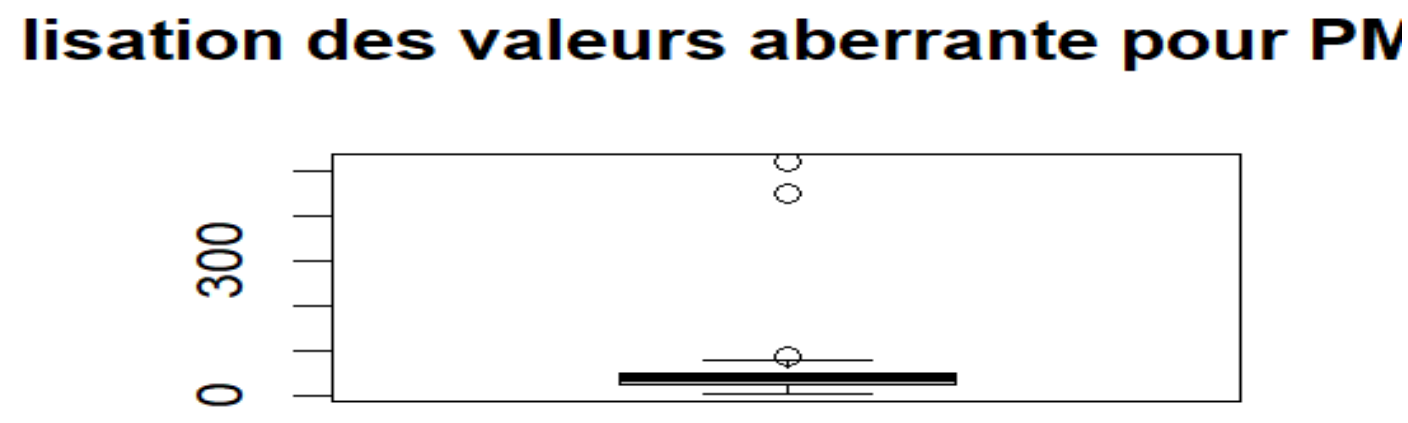

pour NO2_ppb

```
x = df$NO2_ppb
Q1 = quantile(x, 0.25, na.rm = TRUE)
Q3 = quantile(x, 0.75, na.rm = TRUE)
IQR = Q3 - Q1
borne_inf = Q1 - 1.5 * IQR
borne_sup = Q3 + 1.5 * IQR
outliers = x[x < borne_inf | x > borne_sup]
outliers
boxplot(df$NO2_ppb, main = "Visualiser des valeurs aberrantes
                            pour NO2_ppb")
```

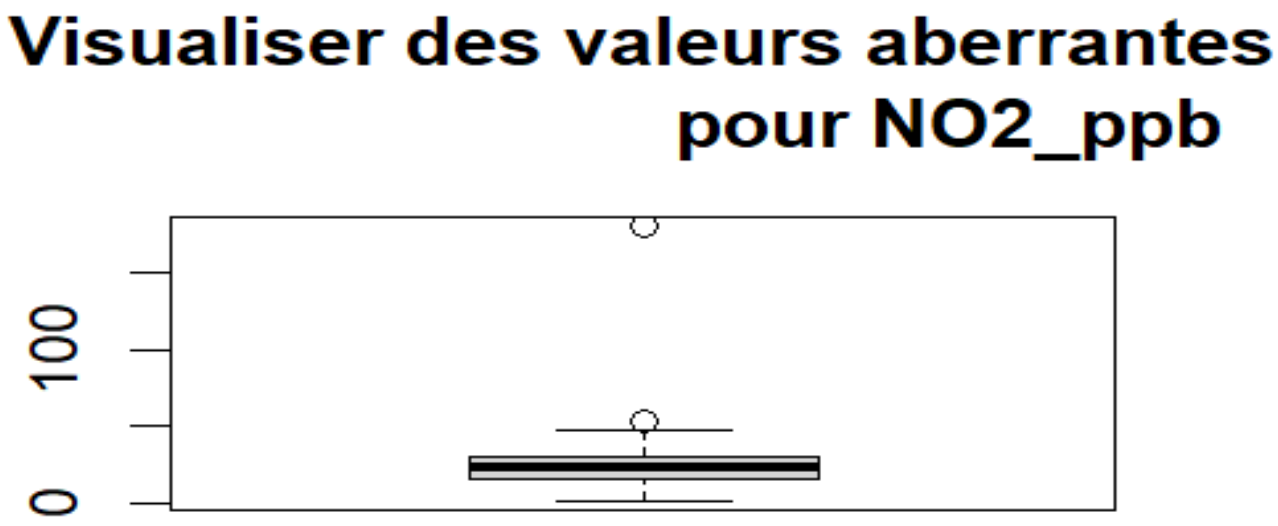

<u>pour Bruit_dB</u>

```
x = df$Bruit_dB
Q1 = quantile(x, 0.25, na.rm = TRUE)
Q3 = quantile(x, 0.75, na.rm = TRUE)
IQR = Q3 - Q1
borne_inf = Q1 - 1.5 * IQR
borne_sup = Q3 + 1.5 * IQR
outliers = x[x < borne_inf | x > borne_sup]
outliers
boxplot(df$Bruit_dB, main = "visualisation des valeurs aberrantes
                        pour Bruit_dB")
```

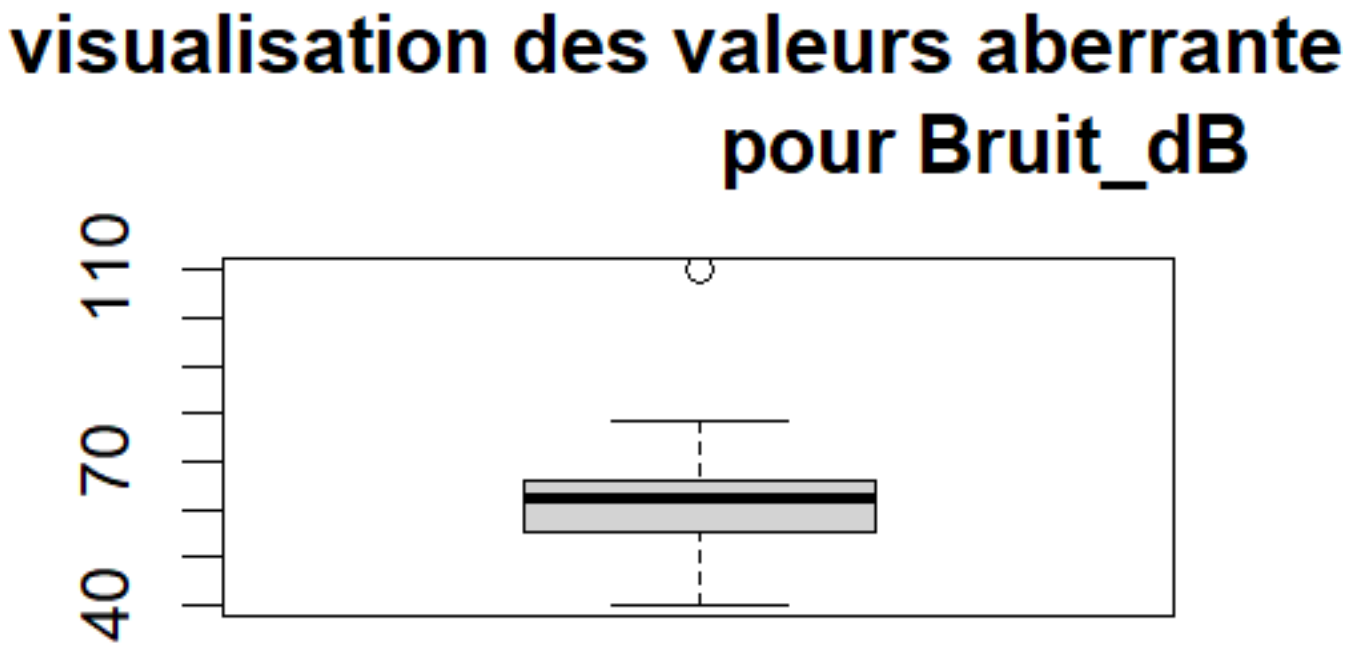

<u>pour NDVI</u>

```
x = df$NDVI
Q1 = quantile(x, 0.25, na.rm = TRUE)
Q3 = quantile(x, 0.75, na.rm = TRUE)
IQR = Q3 - Q1
borne_inf = Q1 - 1.5 * IQR
borne_sup = Q3 + 1.5 * IQR
outliers = x[x < borne_inf | x > borne_sup]
```

```
outliers
boxplot(df$NDVI, main = "Visulisation des valeurs aberrantes
                    pour NDVI")
```

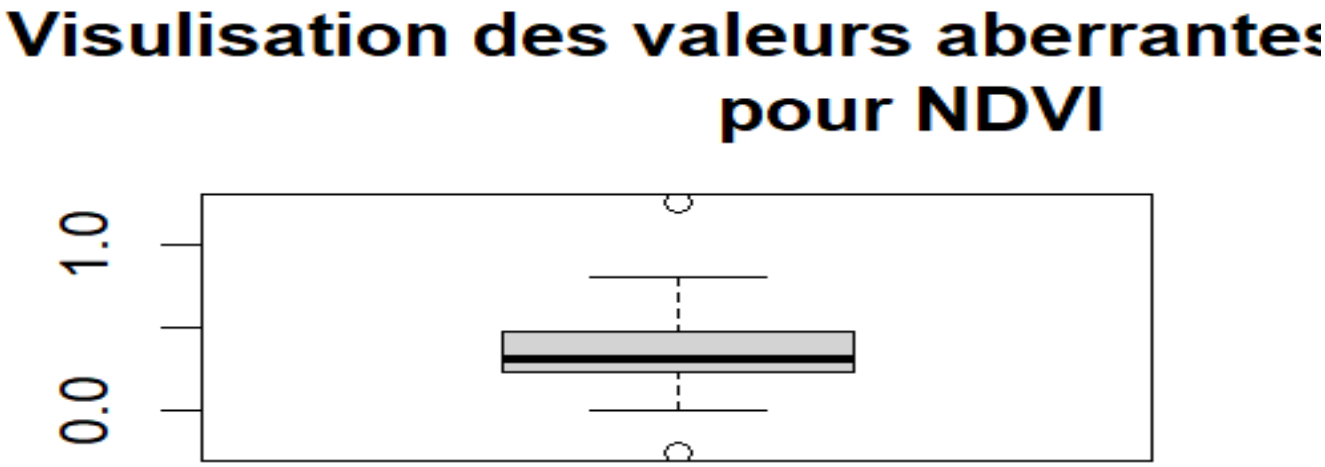

Pour detecter les valeurs aberrantes,j'ai utilisé le boxplot pour faire une visualisation graphiques et IQR pour avoir les valeurs exactes des valeurs aberrantes

.Proposer une strategie

winsoriser

.pour PM25_ugm3

```
library(DescTools)
```

df$PM25_ugm3 <- Winsorize(df$PM25_ugm3)

Justification

Les valeurs élevées de PM2.5 (520, 450 et 86,8 µg/m³)

correspondent à des épisodes de pollution intense,

rares mais physiquement plausibles.

Elles ont été traitées par winsorisation afin de

limiter leur influence statistique tout

en conservant les observations.

.pour NO2_ppb

library(DescTools)

df$NO2_ppb <- Winsorize(df$NO2_ppb)

Justification

Les valeurs élevées de NO_2 (180 ppb et 52,9 ppb)

sont rares mais physiquement plausibles en milieu urbain.

Elles ont été traitées par winsorisation afin de limiter

leur influence sur les analyses statistiques tout

en conservant les observations.

.pour Bruit_dB

library(DescTools)

df$Bruit_dB <- Winsorize(df$Bruit_dB)

Justification

La valeur aberrante de 110 dB pour le bruit est élevée

mais physiquement plausible en milieu urbain.

Elle a été traitée par winsorisation afin

de limiter son influence statistique tout

en conservant l’observation.

.pour NDVI

Supprimer uniquement les valeurs impossibles

```
df <- df %>%
  filter(NDVI >= -1 & NDVI <= 1)
```

Vérification après traitement

```
max(df$NDVI, na.rm = TRUE)
```

Lister les valeurs NDVI > 1

```
df$NDVI[df$NDVI > 1]
```

Justification

La valeur NDVI = 1,25 dépasse la borne théorique maximale

du NDVI et est considérée comme une erreur ;

elle a donc été supprimée.

En revanche, la valeur NDVI = −0,25 appartient à

l’intervalle valide [−1 ; 1] et

représente une surface peu ou non végétalisée ;

elle a été conservée.

B.supression de colonnes

```
df$Agent_collecteur = NULL
print(df)
View(df)
df$Numero_serie_capteur = NULL
print(df)
df$Commentaire  = NULL
print(df)
```

C.Ajouter des colonnes

saison

```
library(dplyr)
library(lubridate)
df <- df %>%
  mutate(Saison = case_when(
    month(Date) %in% 6:10 ~ "Pluie",
    TRUE ~ "Seche"
  ))
table(df$Saison)
View(df)
```

Depassement_PM25

```
library(dplyr)
df <- df %>%
  mutate(Depassement_PM25 = ifelse(PM25_ugm3 > 55, "OUI", "NON"))
table(df$Depassement_PM25)
View(df)
library(dplyr)
```

PM25_log

```
df <- df %>%
  mutate(PM25_log = log(PM25_ugm3 + 0.01))  # si présence de 0
table(df$PM25_log)
View(df)
```

Indice_confort

```
library(dplyr)
```

```
df <- df %>%
  mutate(Indice_confort = Temperature_C + 0.1 * Humidite_pct)
table(df$Indice_confort)
View(df)
```

.D.Visualisations

pour PM25_ugm3

.Histogrammes de PM25_ugm3

```
hist(df$PM25_ugm3,
     main = "Histogramme de PM2.5",
     xlab = "PM2.5 (µg/m³)",ylab = "Fréquence",
     col = "lightblue",)
```

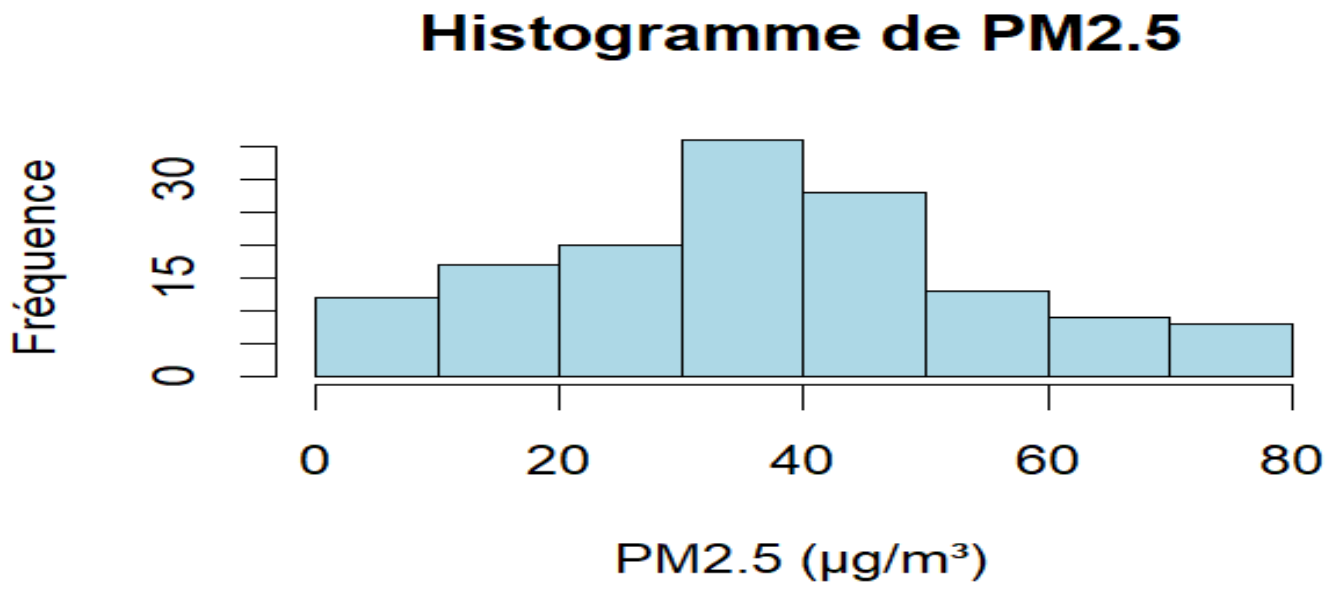

Commentaire de l'histogramme

L'histogramme montre la distribution des concentrations de PM25(en ug/m³).La majorité des observations se situe entre 30-35ug/m³,indiquant que ces valeurs sont les plus fréquentes

On observe également des concentrations plus faibles(inférieures à 20ug/m³)

mais elles sont moins représentées.

Boxplot de PM25_ugm3

```
boxplot(df$PM25_ugm3,
        main = "Boxplot de PM25_ugm3",
        ylab = "PM2.5 (µg/m³)",
        col = "blue")
```

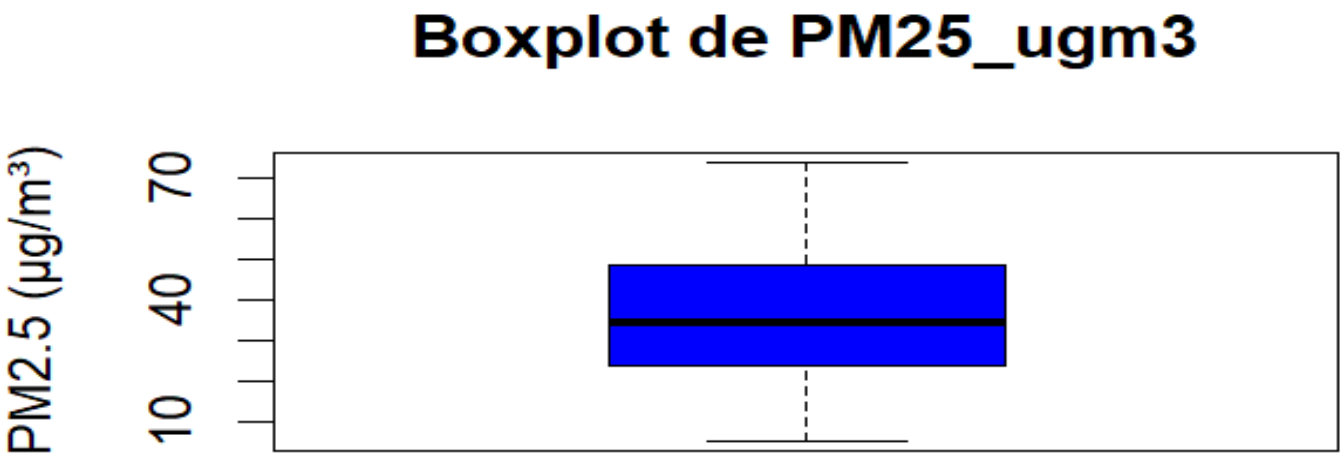

Commentaire du Boxplot de PM25_ugm3

Ceci est un boxplot du PM25_ugm3.La valeur minimale est

d'environ 0.4(µg/m³),la valeur maximale est d'environ 75(µg/m³)

La médiane est d'environ 35(µg/m³)

pour NO2_ppb

Histogramme de NO2_ppb

```
hist(df$NO2_ppb ,
    main = "Histogramme de NO2_ppb ",
    xlab = "NO2 (ppb )",ylab = "Fréquence",
    col = "lightgreen",)
```

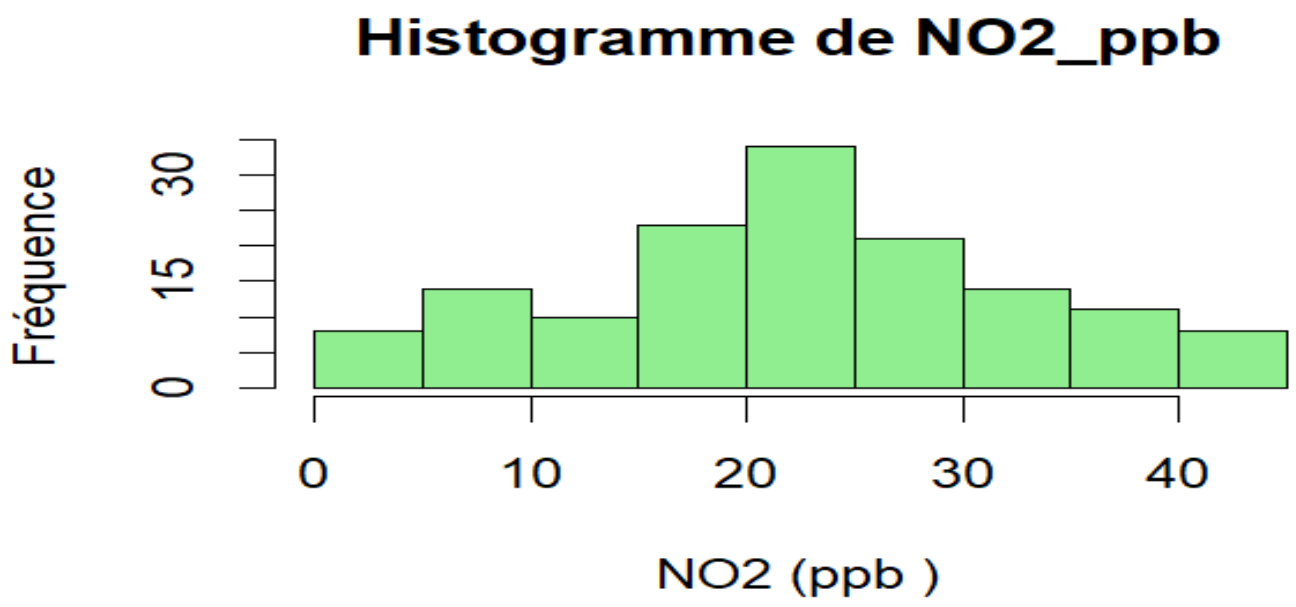

Commentaire de l'histogramme de NO2_ppb :

L'histogramme montre la distribution des concentrations de NO2_ppb.La majorité des observations se situe entre 20-35ppb,indiquant que ces valeurs sont les plus fréquentes On observe également des concentrations plus faibles (inférieures à 15ddp)mais elles sont moins représentées.

Boxplot de NO2_ppb

```
boxplot(df$NO2_ppb,
        main = "Boxplot de NO2_ppb",
```

```
    ylab = "NO2 (ppb )",
    col = "orange")
```

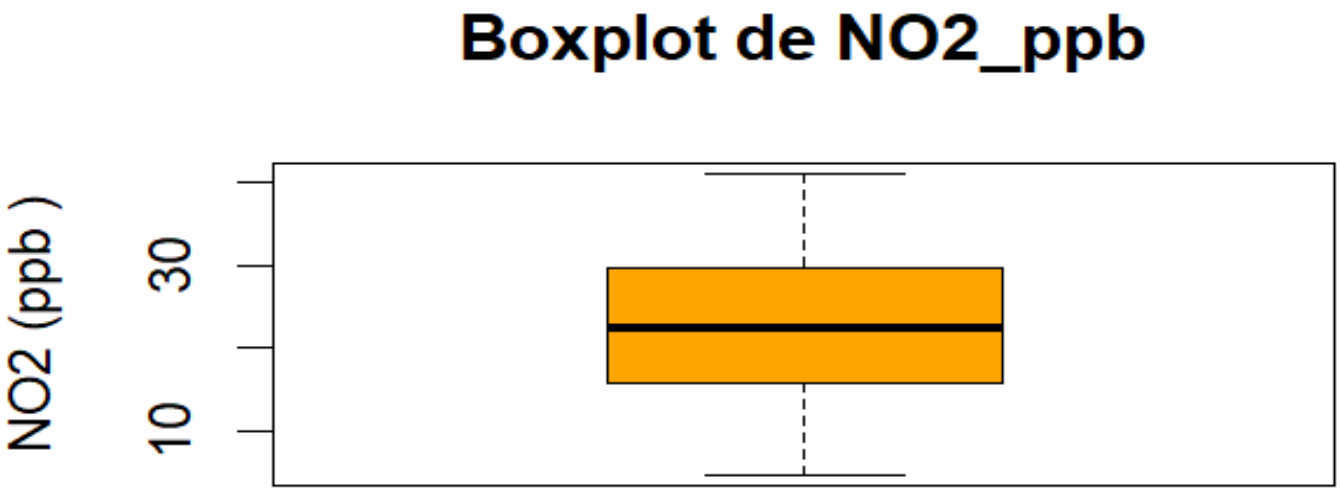

Commentaire du Boxplot de NO2_ppb

Ceci est un boxplot du PM25_ugm3.La valeur minimale est d'environ 2ppb,la valeur maximale est d'environ 42ppb

La médiane est d'environ 22ppb

pour Bruit_dB

.Histogrammes de Bruit_dB

```
hist(df$Bruit_dB  ,
    main = "Histogramme de Bruit_dB  ",
    xlab = "Bruit (dB )",ylab = "Fréquence",
    col = "lightyellow",)
```

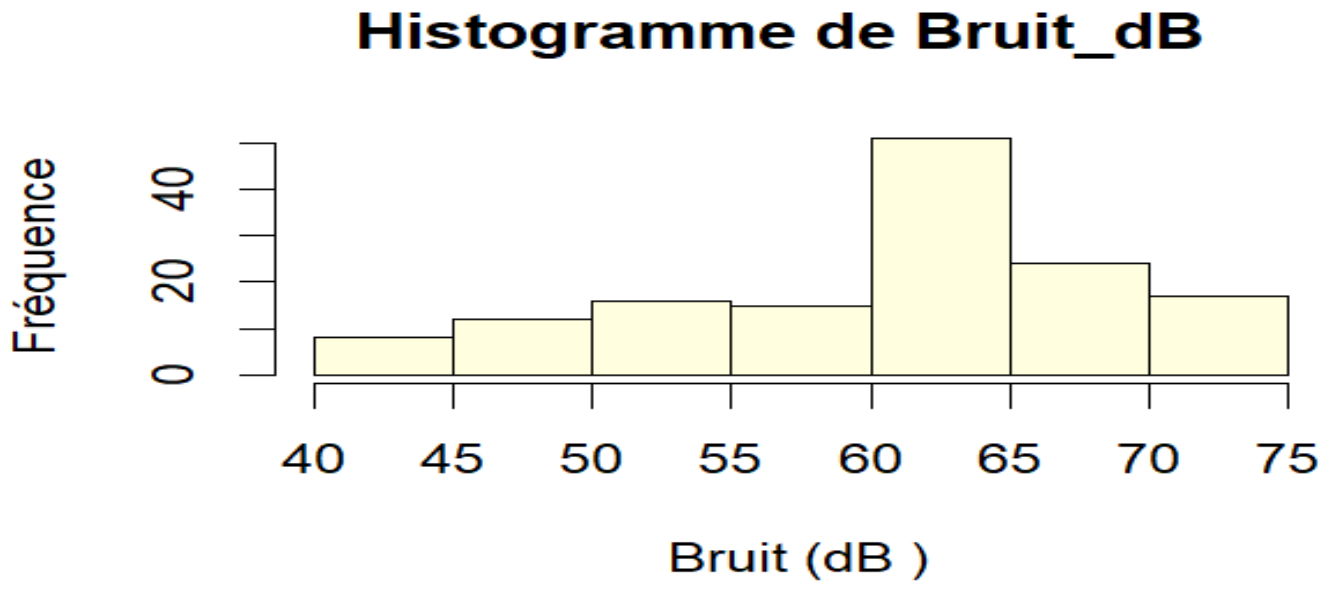

Commentaire de l'histogramme de Bruit_dB :

L'histogramme montre la distribution des concentrations

de NO2_ppb.La majorité des observations se situe entre

25-50dB,indiquant que que ces valeurs sont les plus fréquentes

On observe également des concentrations plus faibles

(inférieures à 20dB)mais elles sont moins représentées.

Boxplot de Bruit_dB

```
boxplot(df$Bruit_dB ,
        main = "Boxplot de Bruit_dB ",
        ylab = "Bruit (dB )",
        col = "orange")
```

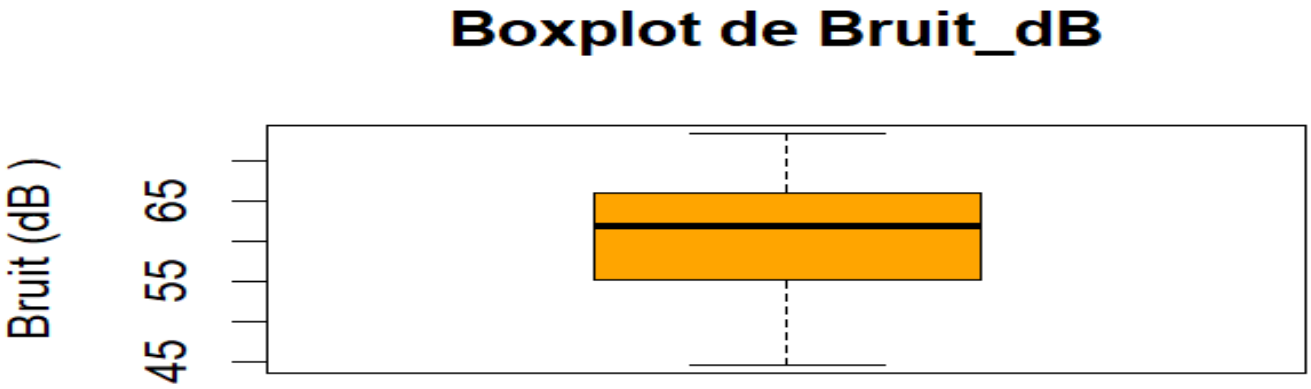

Commentaire du Boxplot de Bruit_dB:

Ceci est un boxplot du PM25_ugm3.La valeur minimale est d'environ 62dB,la valeur maximale est d'environ 78dB

La médiane est d'environ 35(µg/m³)

.Boxplot de PM25_ugm3 par type de zone

```
boxplot(PM25_ugm3 ~ Type_zone,
        data = df,
        main = "Boxplot PM25 par Type de zone",
        xlab = "Type de zone",
        ylim = c(0, 100),
        ylab = "PM2.5 (µg/m³)",
        col = c("skyblue","lightgreen","orange"))
table(df$Type_zone)
```

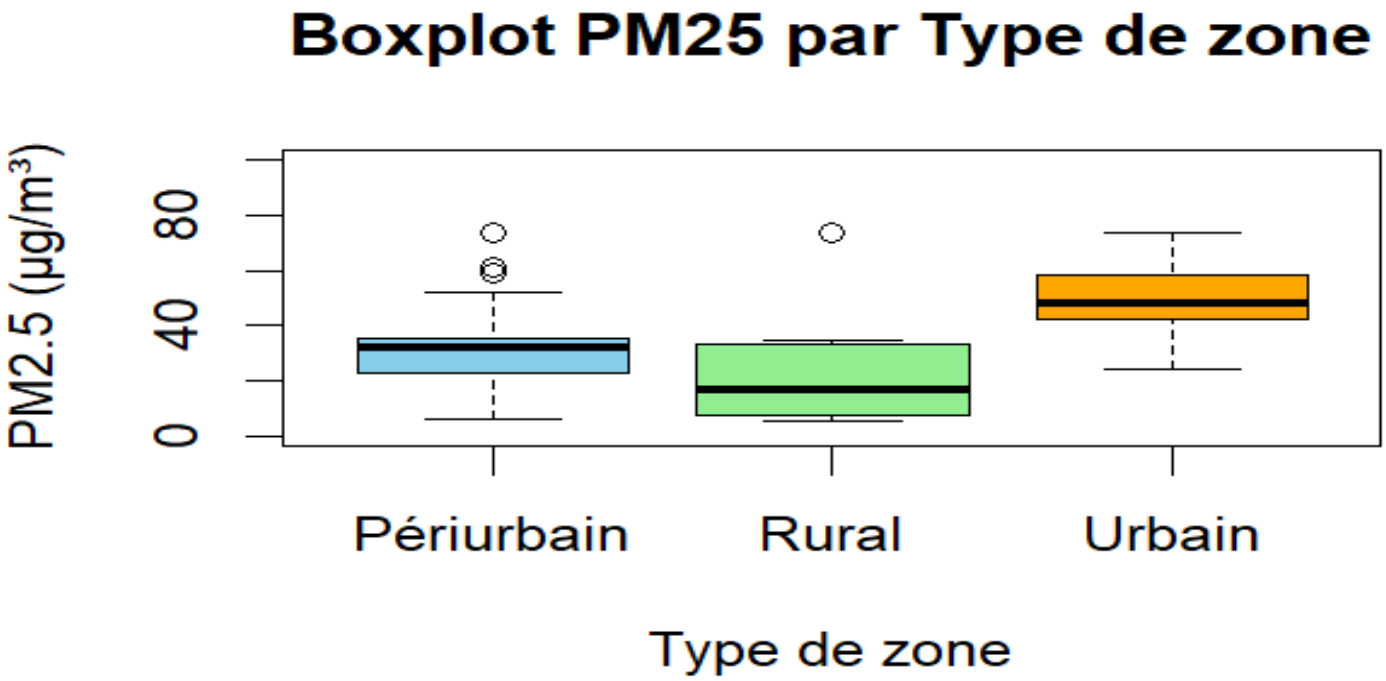

table(df$Type_zone)

```
Périurbain      Rural     Urbain
        47         36         60
```

Commentaire du Boxplot de PM25_ugm3 par type de zone

Le boxplot montre que les concentrations de PM2.5 sont les plus élevées en zone urbaine, avec une médiane autour de 45 µg/m³.

Les zones périurbaines présentent des valeurs intermédiaires avec une médiane de 28 µg/m³,

tandis que les zones rurales affichent les concentrations

les plus faibles, avec une médiane nettement inférieure à 20 µg/m³.

boxplot de PM25_ugm3 par Usage_sol

```
boxplot(PM25_ugm3 ~ Usage_sol,
        data = df,
        main = "Boxplot PM25 par Usage du sol",
        xlab = "Usage du sol",
        ylab = "PM2.5 (µg/m³)",
        col = "lightblue")
```

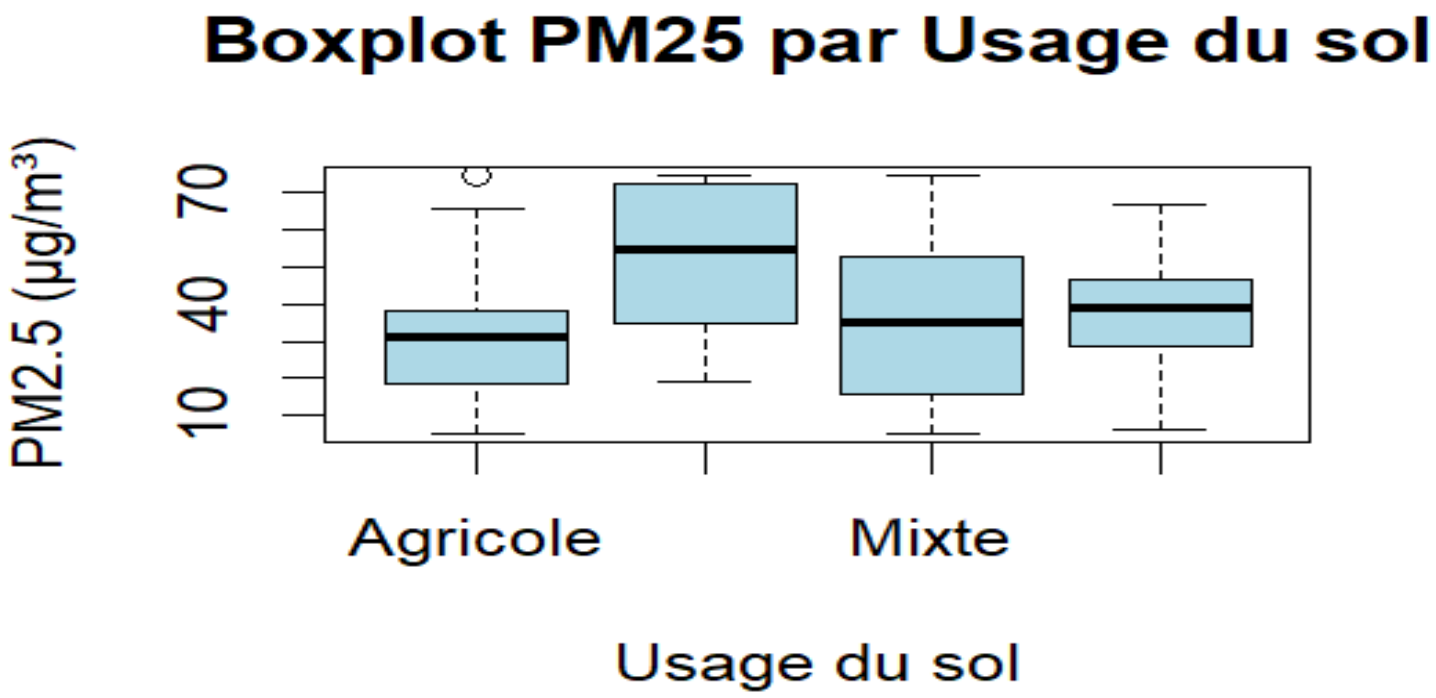


```
table(df$Usage_sol)
```

```
Agricole  Industriel       Mixte Résidentiel 60
24          24          35
```

Commentaire du boxplot de PM25_ugm3 par Usage_sol

Les zones industrielles enregistrent les niveaux médians

les plus élevés(environ 55 kg/m³), suivies des zones

mixtes (environ 35 kg/m³), puis des zones résidentielles

(environ 40 kg/m³). Les zones agricoles présentent la

concentration médiane la plus faible (environ 32 kg/m³).

Cette hiérarchie est conforme aux attentes, les activités industrielles étant une source majeure d'émissions de particules.

.Scatter de PM25_ugm3 VS NO2_ppb(avec tendance)

```
library(ggplot2)
ggplot(df, aes(x = NO2_ppb, y = PM25_ugm3)) +
  geom_point(color = "blue") +                # scatter plot
  geom_smooth(method = "lm", color = "red") + # droite de tendance
  labs(title = "PM2.5 vs NO2",
       x = "NO2 (ppb)",
       y = "PM2.5 (µg/m³)") +
  theme_minimal()
```

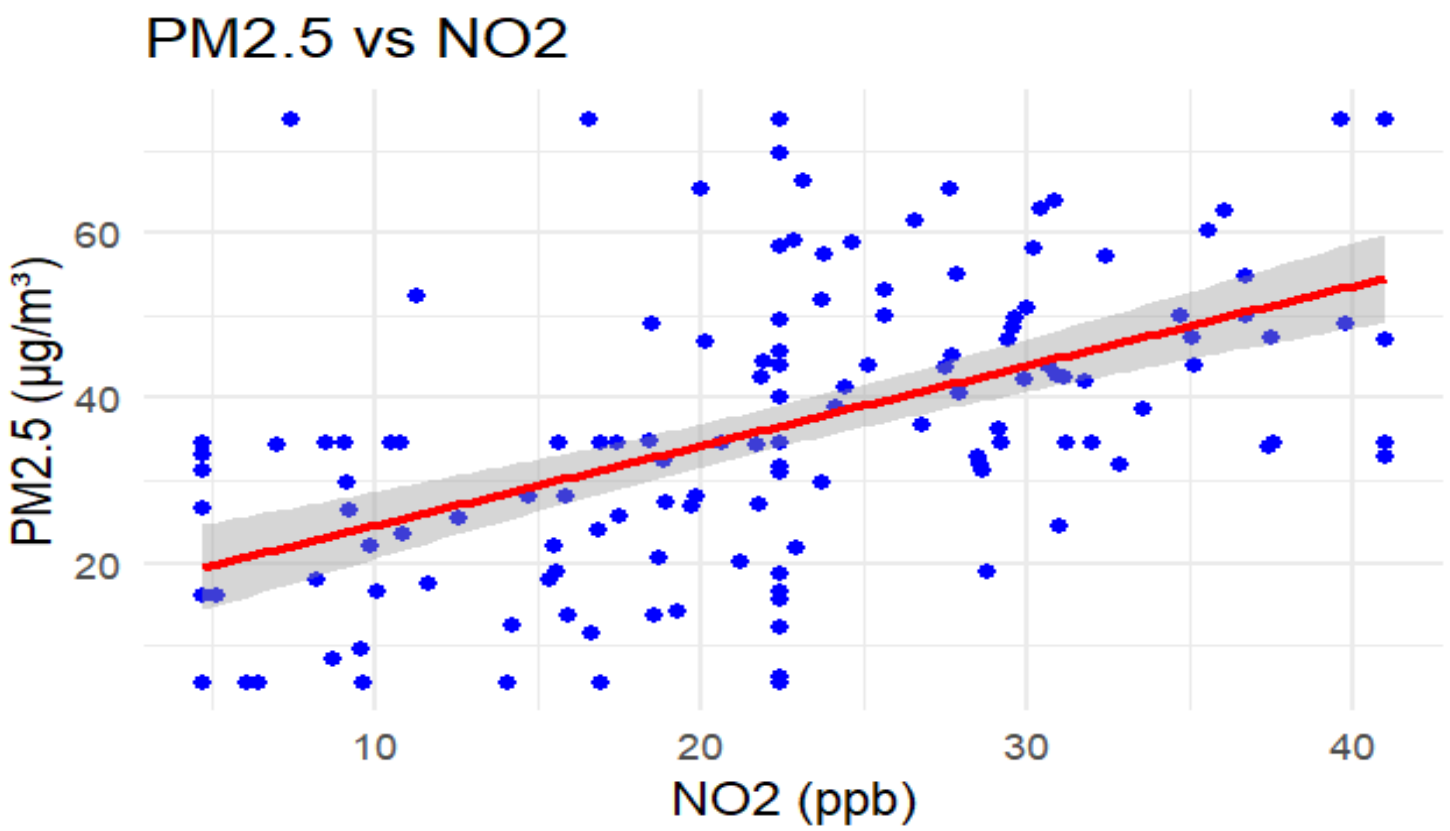

Commentaire du Scatter de PM25_ugm3 VS NO_2

Le nuage de points et la droite de régression montrent une relation positive, ce qui est cohérent avec le test de corrélation (Spearman) indiquant une corrélation modérée entre PM2.5 et NO_2.

.Scatter de PM25_ugm3 VS NDVI

```
library(ggplot2)
ggplot(df, aes(x = NDVI, y = PM25_ugm3)) +
  geom_point(color = "green") +                # scatter
   geom_smooth(method = "lm", color = "red") +  # droite de tendance
  labs(title = "Relation PM2.5 vs NDVI",
       x = "NDVI",
```

```
    y = "PM2.5 (µg/m³)") +
theme_minimal()
```

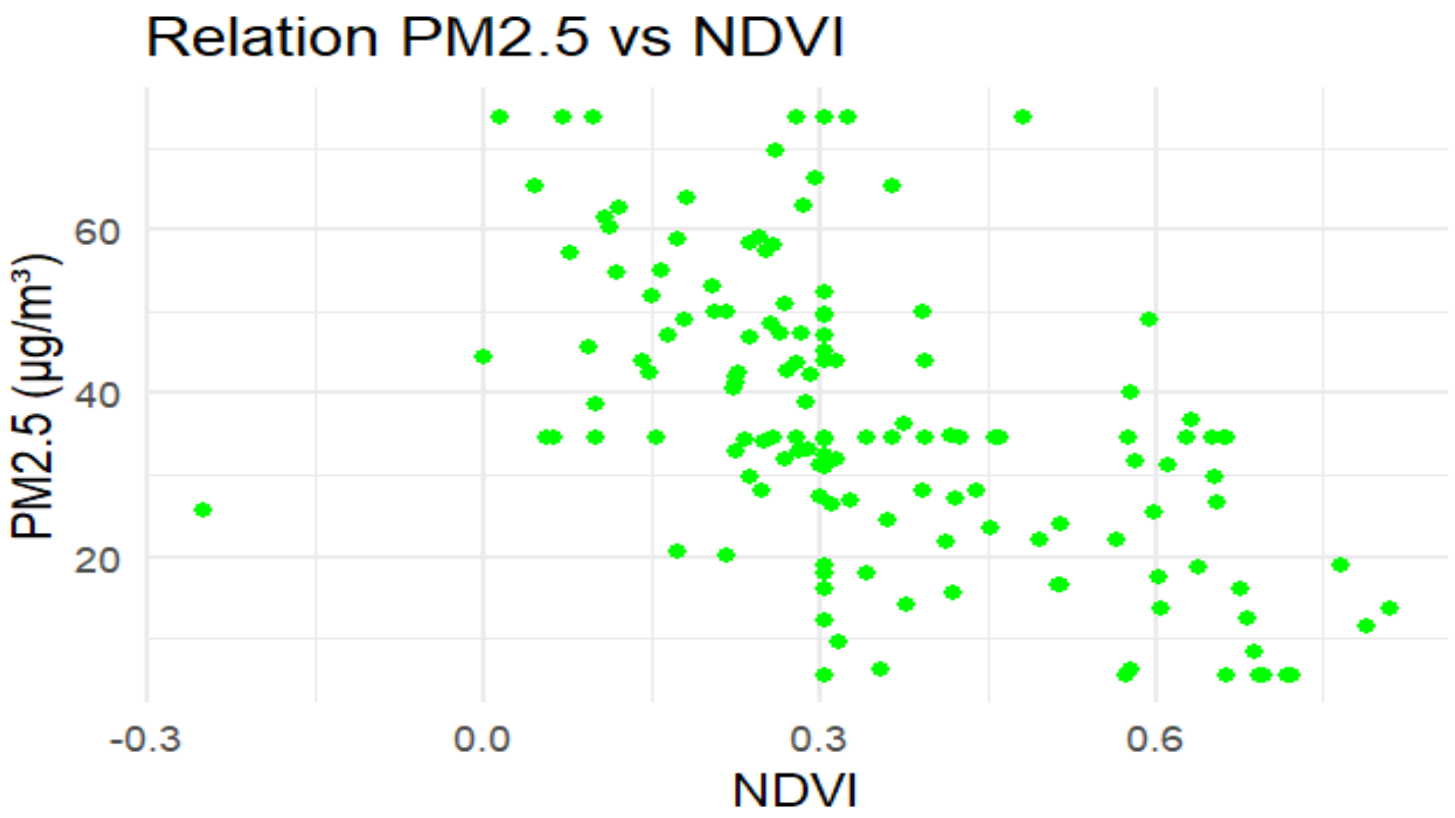

Commentaire de la relation entre PM2.5 VS NDVI

Le graphique présenté illustre la relation entre la concentration de particules fines PM2.5 (en µg/m³) et l'Indice de Végétation par Différence Normalisée (NDVI). On observe une tendance générale : plus le NDVI est élevé, plus la concentration de PM2.5 tend à diminuer.

Série temporelle PM2.5 par mois et par zone

1. S'assurer que Date est au bon format

```
df$Date <- as.Date(df$Date)
```

2. Créer la variable Mois (Année-Mois)

```
df$Mois <- format(df$Date, "%Y-%m")
```

3. Calcul moyenne mensuelle PM2.5 par zone

```
library(dplyr)
pm_zone_mois <- df %>%
  group_by(Mois, Type_zone) %>%
  summarise(PM25_moy = mean(PM25_ugm3, na.rm = TRUE)) %>%
  ungroup()
```

4. Convertir Mois en date pour bon affichage

```
pm_zone_mois$Mois <- as.Date(paste0(pm_zone_mois$Mois, "-01"))
#5. Graphique série temporelle
library(ggplot2)
ggplot(pm_zone_mois, aes(x = Mois, y = PM25_moy,
                         color = Type_zone, group = Type_zone)) +
  geom_line(size = 1.2) +
  geom_point() +
  labs(title = "Série temporelle mensuelle du PM2.5 par type de zone",
       x = "Mois",
       y = "PM2.5 moyen (µg/m3)",
       color = "Type de zone") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

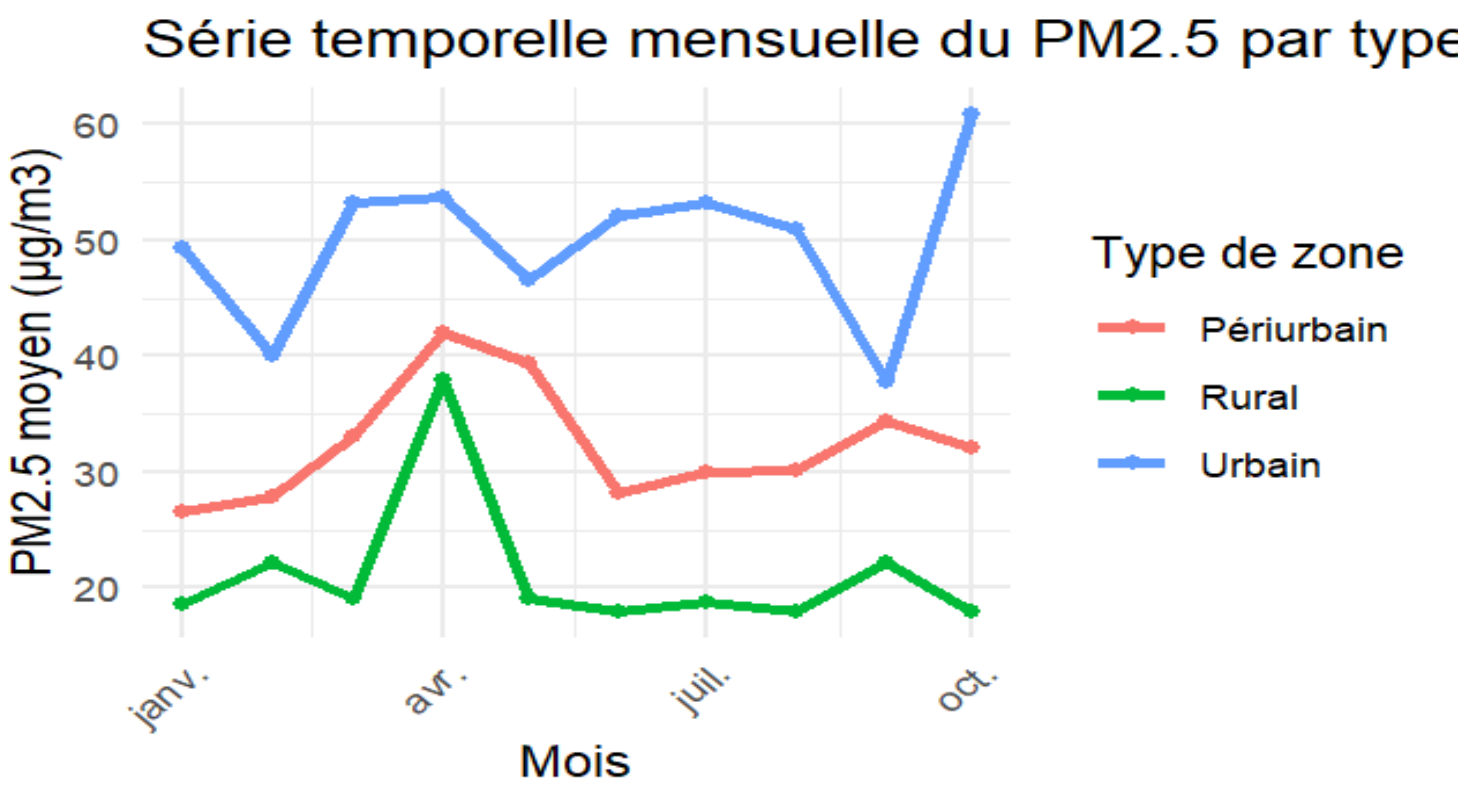

Commentaire de la serie Série temporelle mensuelle du

PM2.5 par type de zone

Le PM2.5 est systématiquement plus élevé en zone urbaine,

suivi des zones périurbaines, tandis que les zones rurales

présentent les niveaux les plus faibles.

On observe également une variabilité temporelle,

avec des pics à certains mois, indiquant une influence saisonnière.

4. Heatmap avec ggcorrplot

library(corrplot)

library(ggcorrplot)

library(dplyr)

ggcorrplot(mat_cor,

```
lab = TRUE,
title = "Heatmap des corrélations des variables quantitatives",
type = "upper",
colors = c("blue", "white", "red"))
```

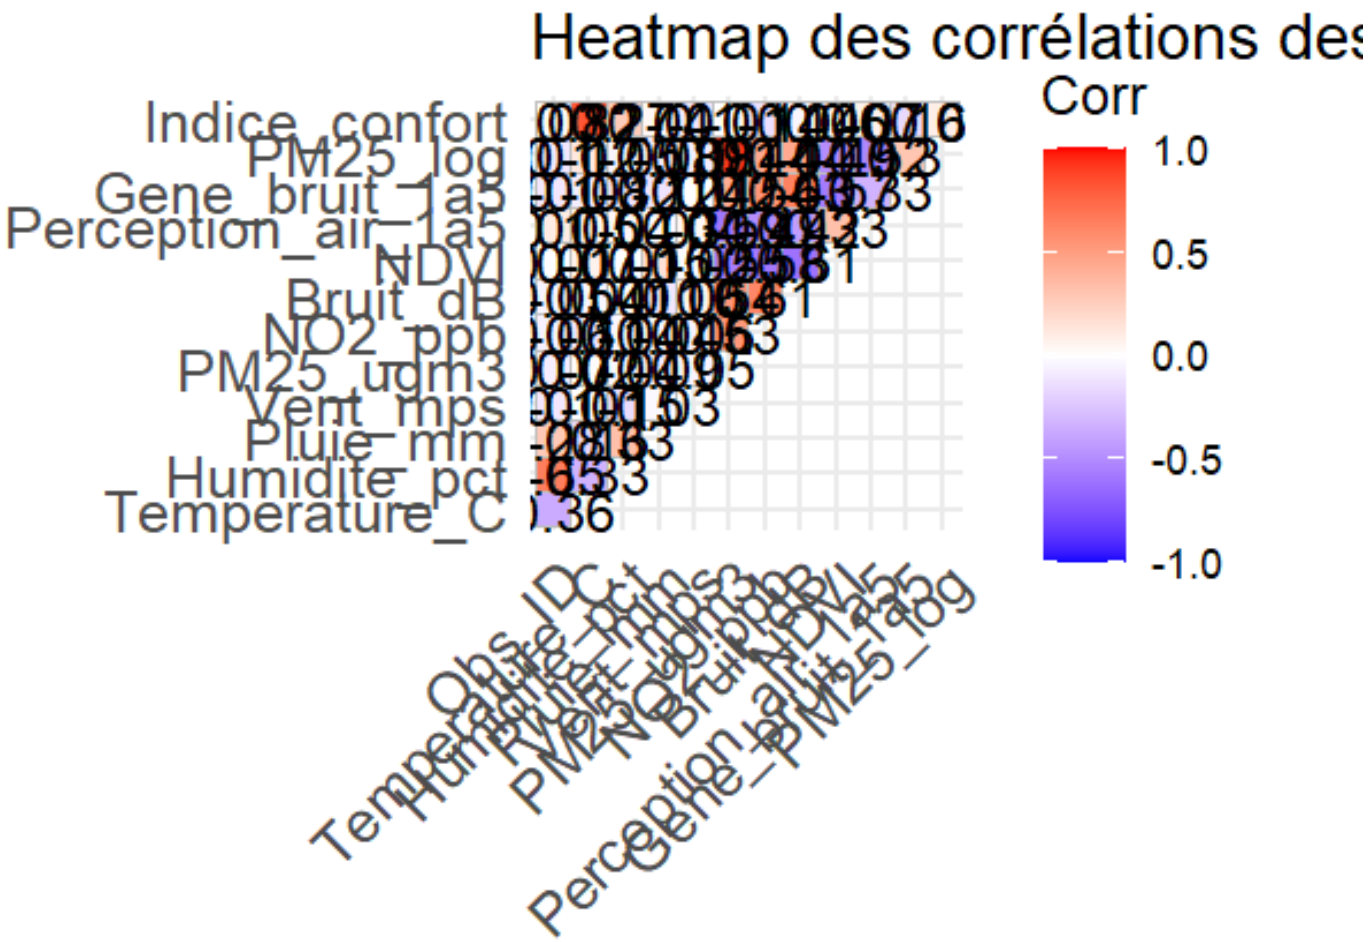

Commentaire

1.Corrélations positives très fortes :

PM25_log avec PM25_µg/m³ : r = 0.91 très fortement corrélés

(le PM2.5_log et PM2.5ug/m³ évaluent dans le sens c'est à

dire si l'un augmente ,l'autre augmente aussi)

Humidité_pct avec Pluie_mm : r = 0.65

plus il pleut, plus l'humidité est élevée(les deux variables s'évaluent dans le même sens ')

Indice_confort avec Perception_air_1à5 : r = 0.10

(faible mais Indice_confort et Perception_air_1à5 s'évaluent dans le même sens:)

Corrélations négatives très fortes :

Perception_air_1à5 avec PM25_log : r = -0.59

Plus la pollution (PM2.5) augmente, plus la perception de la qualité de l'air se dégrade ,les deux variables s' évaluent dans le sens opposé.

NDVI (végétation) avec Bruit_dB : r = -0.61

Les zones végétalisées sont généralement moins bruyantes

NDVI avec PM25_log : r = -0.55

La végétation est associée à une pollution plus faible

3)Questions statistiques

3.1).Quali * Quali

Depassement_PM25 * Type_zone

1.Analyse univariée

Depassement_PM25

table(df$Depassement_PM25)

```
 NON OUI
 120  23
```

```
On a plus de Non Depassement(120)
Que de Depassement(23)
```

Type_zone

table(df$Type_zone)

```
Périurbain      Rural     Urbain
        47         36         60
```

On plus de Urbain(60) suivi du Périurbain(47) puis vient en dernier la zone Rural(36)

2.Analyse bivariée

Tableau de contingence

tab <- table(df$Depassement_PM25, df$Type_zone)

tab

```
     Périurbain Rural Urbain
NON          44    35     41
OUI           3     1     19
```

interpretation du Tableau de contingence

pour les zones Périurbain on a :

44 zones sans Depassement_PM25

3 zones avec Depassemen_PM25

pour les zones Rural on a

35 zones sans Depaseement_PM25

1 zones avec Depassement_PM25

pour les zones Urbain on a

41 zones sans Depassement_PM25

19 zones avec Depassement_PM25

3.Répartition des Types de zone selon le Depassement_PM25

library(ggplot2)

```
ggplot(df, aes(x = Depassement_PM25, fill = Type_zone)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition des Types de zone selon le Depassement_PM25",
       x = "Depassement_PM25", y = "Proportion") +
  theme_minimal()
```

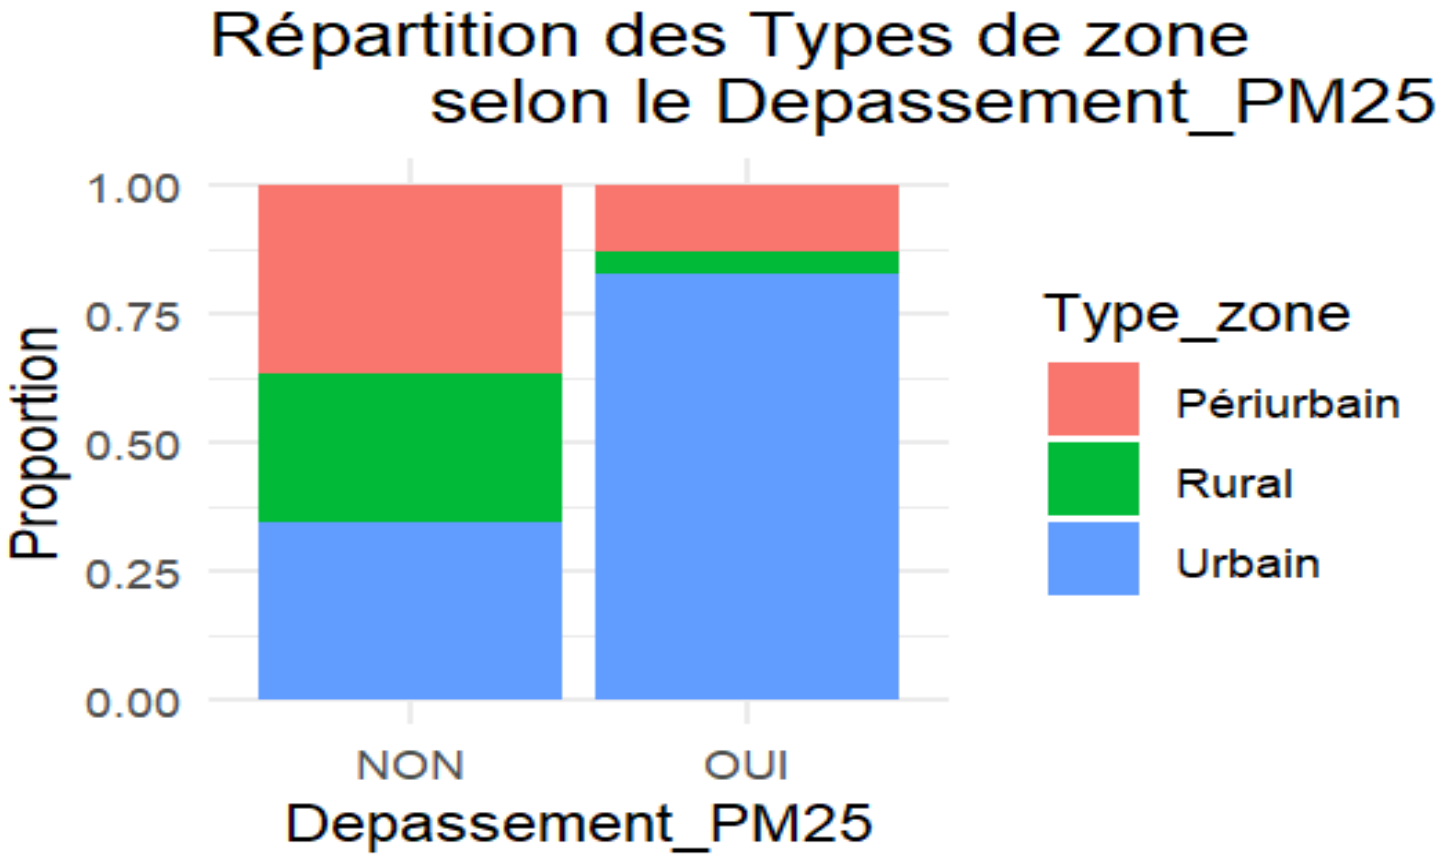

Interpretation du ggplot:

Quand il n'y a pas de dépassement (NON)

on voit un mélange plus équilibré

Quand il y a dépassement (OUI)

on observe surtout :

✓ beaucoup plus de zones urbaines

✓ beaucoup moins de zones rurales

✓ un peu de périurbain

4.Test du Chi-deux d'indépendance

Condition d'application:

on a 2 variables qualitatives

au moins 5 observations dans chaque catégorie

chaque individu appartient à une seule catégorie pour chaque variable

donc on peut appliquer le Test du Chi-deux

Hypothése nulle: il n'y a pas de lien

Hopytése alternative : il y a un lien entre les deux variables

```
chi <- chisq.test(tab)
chi
```

la p-value(8.297e-05) est inférieure à 5% donc on rejete H0 et on accepte H1 . Donc il y'a une relation significative entre le Depassement du PM25 et le Type de zone.Donc le Depassement du PM25 n'est pas independant du type de zone

5.Mesure d'intensité : V de Cramer

```
library(vcd)
assocstats(tab)
```

d'apres le v de Cramer, le coefficient = 0.363 qui est superieure à 0.3

Donc il y' a une forte relation entre le Depassement du PM25 et le Type de zone

Conclusion Finale:

on peut conclure que le Depassement du PM25 depend du type de zone

3.2).Quali * Quali

Brulage_dechets * Type_zone

1.Analyse univariée

Brulage_dechets

table(df$Brulage_dechets)

```
Non Oui
116  27
```

On a plus de sans Brulage de dechets(116)

Que de Brulage de dechets(27)

Type_zone

table(df$Type_zone)

```
Périurbain      Rural     Urbain
        47         36         60
```

On plus de Urbain(60) suivi du Périurbain(47) puis vient en dernier la zone Rural(36)

2.Analyse bivariee

Tableau de contingence

tab <- table(df$Brulage_dechets, df$Type_zone)

tab

```
      Périurbain Rural Urbain
Non           39    27     50
Oui            8     9     10
```

interpretation du Tableau de contingence

pour les zones Périurbain on a

39 zones sans Brulage_dechets

8 zones avec Brulage_dechets

Pour les zones Rural on a

27 zones sans Brulage_dechets

9 zones avec Brulage_dechets

pour les zones Urbain on a

50 zones sans Brulage_dechets

10 zones avec Brulage_dechets

3.Répartition des Types de zone selon le Brulage_dechets

```
ggplot(df, aes(x = Brulage_dechets, fill = Type_zone)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition des Types de zone selon  Brulage_dechets",
       x = "Brulage_dechets", y = "Proportion") +
  theme_minimal()
```

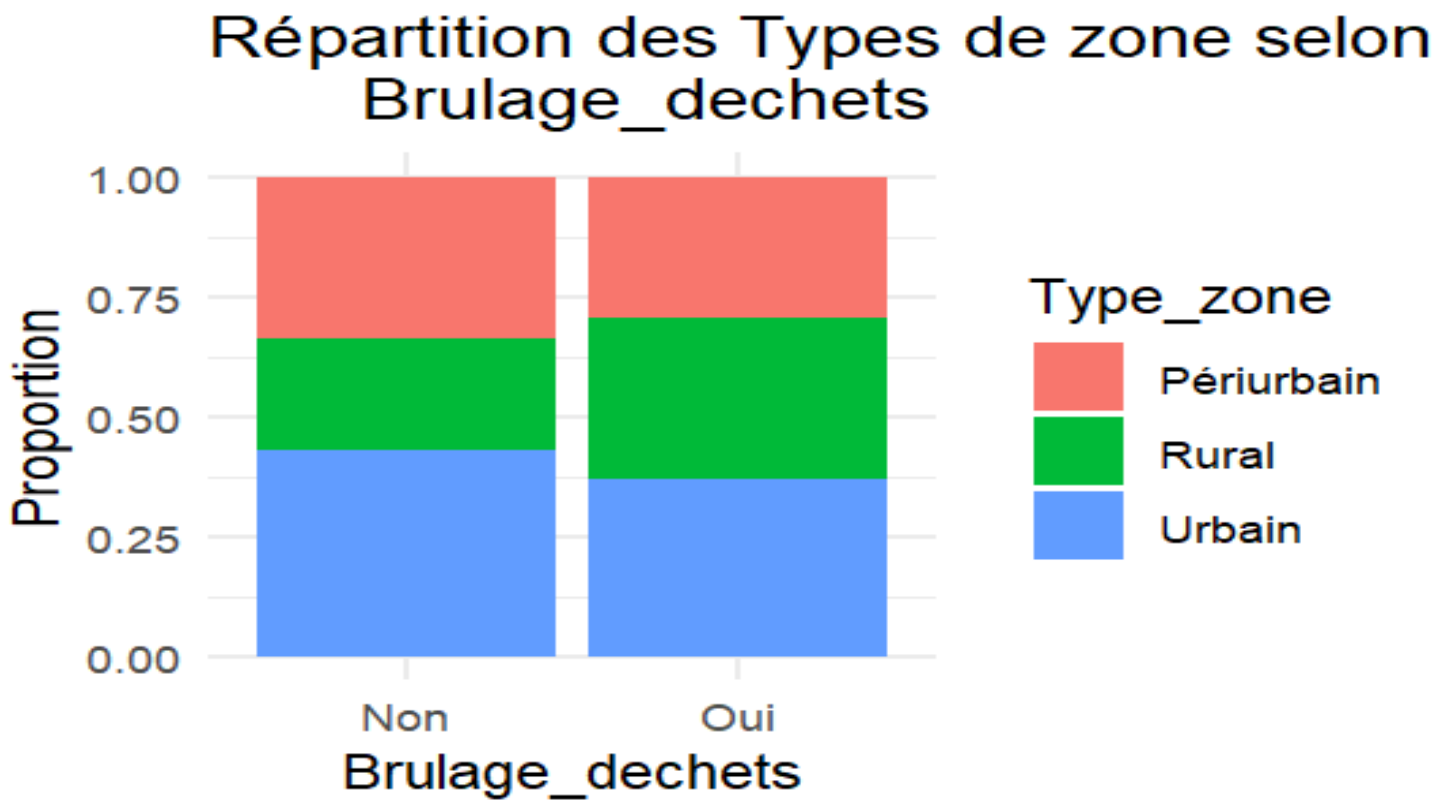

Interpretation du ggplot:

Lorsque le brûlage des déchets est absent (Non),

la répartition des types de zone est relativement

équilibrée, avec une présence importante des zones urbaines,

suivies des zones rurales et périurbaines.

Lorsque le brûlage des déchets est présent (Oui),

on observe une augmentation relative de la proportion

des zones rurales, tandis que la part des zones urbaines

diminue légèrement.

Les zones périurbaines restent présentes dans

les deux situations, avec une variation modérée.

4.Test statistique

Condition d'application: on a 2 variables qualitatives

au moins 5 observations dans chaque catégorie

chaque individu appartient à une seule catégorie pour chaque variable

donc on peut appliquer le Test du Chi-deux

Hypothése nulle: il n'y a pas de lien

Hopytése alternative : il y a un lien entre les deux variables

```
chi <- chisq.test(tab)
chi
```

la p-value(0.5548) est superieure à 5% donc on rejete H1 et on

acepte H0 . Donc il n' y'a pas de relation significative

entre le Brulage de dechets et le Type de zone.Donc le

Brulage de dechets est independant du type de zone

Concluson

on peut conclue que le Brulage de dechets ne depend pas du type de zone

3.3.Quanti × Quanti : Pearson vs Spearman

PM25_ugm3 vs NO2_ppb

1. Chargement des librairies

library(ggplot2)

2. Description univariée

Pour PM25_ugm3

summary(df$PM25_ugm3)

interprétation du summary

5.566 reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inférieure ou égale à 24.122

75% des observations ont une valeur inférieure ou égale à 48.703

50% des observations ont une valeur inférieure ou égale à34.597

74.063 represente la valeur maximale observée(la plus grande)

la moyenne des observations de PM25_ugm3 est 36.628

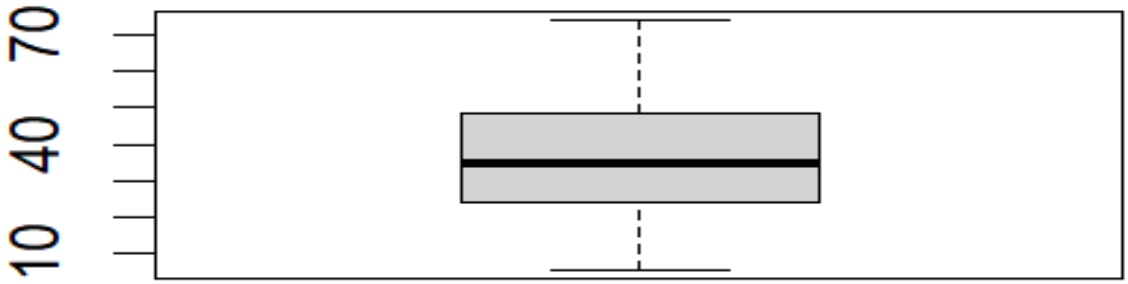

le boxplot montre ce qu'on a sur le summary

Commentaire du Boxplot de PM25_ugm3

Ceci est un boxplot du PM25_ugm3.La valeur minimale est

d'environ 0.4(µg/m³),la valeur maximale est d'environ 75(µg/m³http://127.0.0.1:40396/graphics/01a33798-8761-4b79-8dda-a9a2b20f8dda.png)

La médiane est d'environ 35(µg/m³)

Pour la température

summary(df$NO2_ppb)

interpretation du summary

3.835 représente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inféreure ou égale à 15.736

75% des observations ont une valeur inférieure ou égale à 29.608

50% des observations ont une valeur inférieure ou égale à 22.393

41.113 represente la valeur maximale observée(la plus grande)

la moyenne des observations de PM25_ugm3 est 22.405

boxplot(df$NO2_ppb)

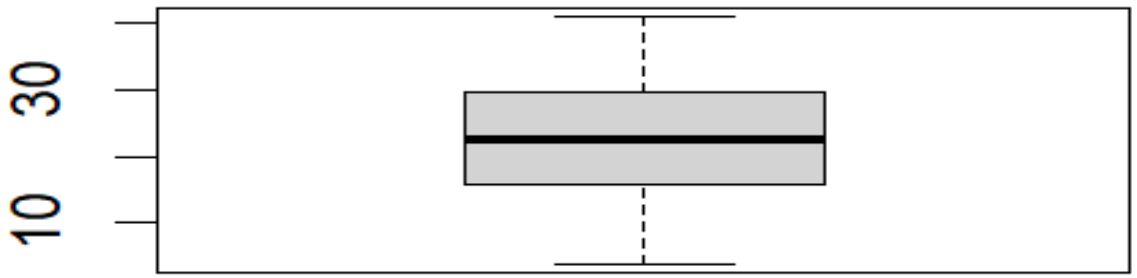

le boxplot montre ce qu'on a sur le summary

Commentaire du Boxplot de NO2_ppb

Ceci est un boxplot du PM25_ugm3.La valeur minimale est

d'environ 2ppb,la valeur maximale est d'environ 42ppb

La médiane est d'environ 22ppb

3.Description bivariée

Nuage de points entre PM25_ugm3 et NO2_ppb

```
plot(df$PM25_ugm3, df$NO2_ppb,
     main = "Relation entre PM25et NO2",
```

xlab = "PM2.5 (µg/m³)", ylab = "NO2 (ppb)")

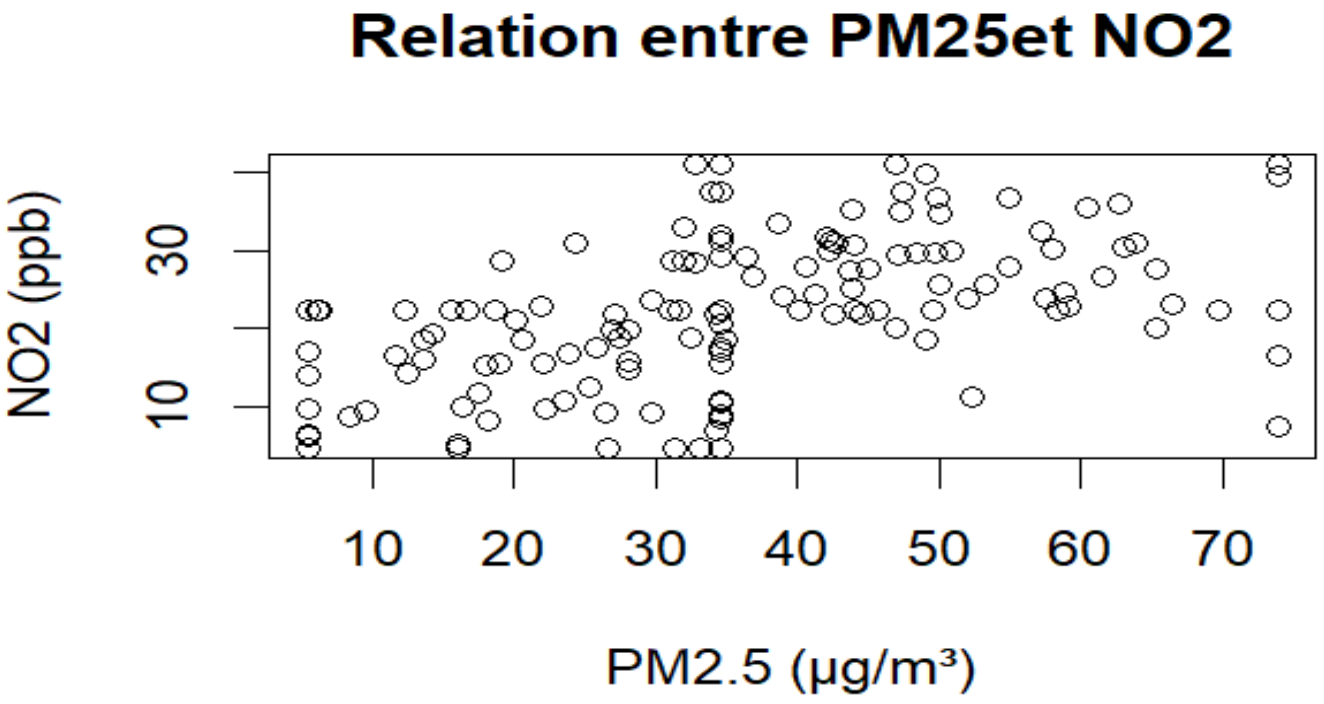

interpretation du Nuage de point

Le nuage de points montre une tendance croissante :

lorsque le PM2.5 augmente, le NO_2 tend aussi à augmenter.

Cela indique une corrélation positive modérée entre

les deux polluants, suggérant des sources ou des

conditions communes (trafic, activités urbaines).

Donc il n'y'a de linéarité entre PM25_ugm3 et NO2_ppb

Vérification de la linéarité et de la normalité

Pour la linéarité (voir 3.Description bivariée)

Pour la normalité

shapiro.test(df$PM25_ugm3)

shapiro.test(df$NO2_ppb)

D'apres le test de shapiro on a le p-value de

PM25_ugm3(0.00407) et le p-value de NO2_ppb(0.004795)

sont tous inferieures à 0.05.Donc la normalité n'est pas vérifiée.

Condition d'utilisation: on a deux variables

(PM25_ugm3 et NO2_ppb) quantitatives ,les données

les données ne sont pas normalement distribuées,

la relation entre PM25_ugm3 et NO2_ppb est monotone (non linéaire)

Donc on peut utiliser le Test de corrélation de spearman

5. Test de corrélation

cor.test(df$PM25_ugm3, df$NO2_ppb, method="spearman")

D'aprés le Test de corrélation de spearman,

Le coefficient de corrélation entre le PM2.5 et le NO_2

est de 0,5685912, ce qui indique une corrélation positive

modérée entre PM25_ugm3 et NO2_ppb

Conclusion

on peut conclue que:PM2.5 est corrélé positivement à NO_2,

ce qui signifie que lorsque NO_2 augmente,

PM2.5 a tendance à augmenter également.

3.4).Quanti × Quanti : Pearson vs Spearman

NDVI vs PM25_ugm3

Analyse de la corrélation entre deux variables quantitatives

Hypothése nulle (H0): il n'y a pas de corrélation

Hopytése alternative (H1): il y a une corrélation entre les deux variables

1.Chargement des librairies

library(ggplot2)

2. Description univariée

Pour PM25_ugm3

summary(df$PM25_ugm3)

interpretation du summary

5.566reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inférieure ou égale à 24.122

75% des observations ont une valeur inférieure ou égale à 48.703

50% des observations ont une valeur inférieure ou égale à34.597

74.063 represente la valeur maximale observée(la plus grande)

la moyenne des observations de PM25_ugm3 est 36.628

boxplot(df$PM25_ugm3)

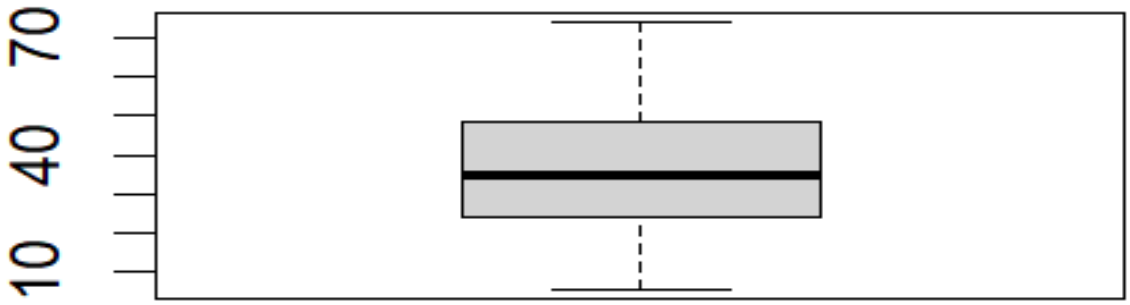

le boxplot montre ce qu'on a sur le summary

Commentaire du Boxplot de PM25_ugm3

Ceci est un boxplot du PM25_ugm3.La valeur minimale est

d'environ 0.4(µg/m³),la valeur maximale est d'environ 75(µg/m³http://127.0.0.1:40396/graphics/01a33798-8761-4b79-8dda-a9a2b20f8dda.png)

La médiane est d'environ 35(µg/m³)

Pour la NDVI

summary(df$NDVI)

interpretation du summary

-0.2500 reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inférieure ou égale à 0.2349

75% des observations ont une valeur inférieure ou égale à 0.4590

50% des observations ont une valeur inférieure ou égale à 0.3050

0.8090 represente la valeur maximale observée(la plus grande)

la moyenne des observations de NDVI est 0.3487

boxplot(df$NDVI)

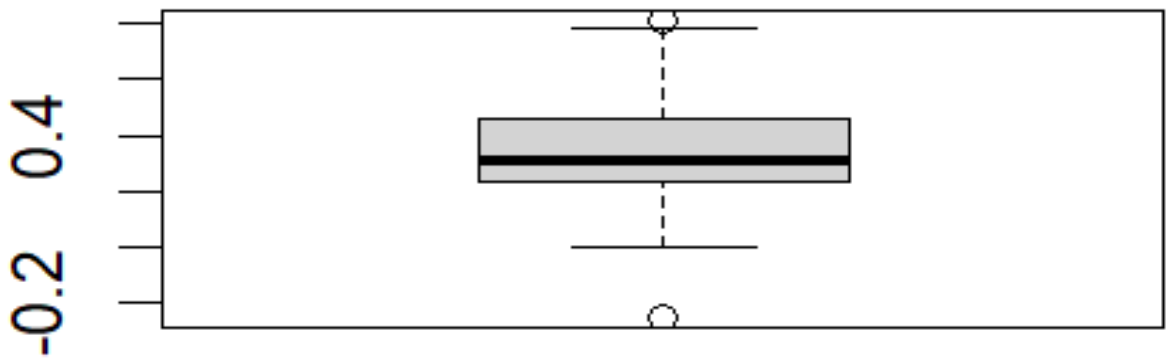

le boxplot montre ce qu'on a sur le summary

Commentaire du Boxplot de NDVI

Ceci est un boxplot du PM25_ugm3.La valeur minimale est

d'environ 0.0,la valeur maximale est d'environ 0.8

La médiane est d'environ 0.3

.3 Description bivariée

Nuage de points entre les 2 variables

```
plot(df$PM25_ugm3, df$NDVI,
     main = "Relation entre PM25et NDVI",
     xlab = "PM2.5 (µg/m³)", ylab = "NDVI")
```

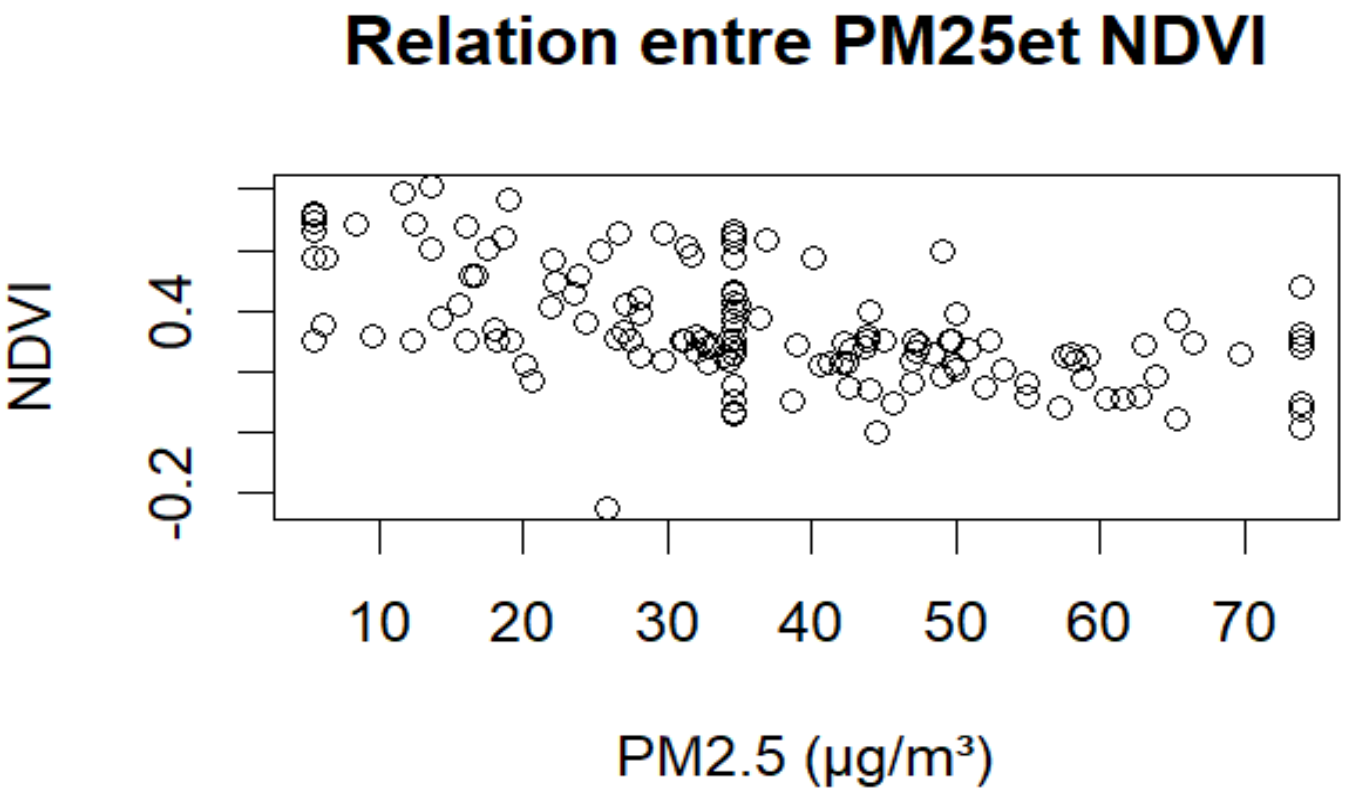

interpretation du nuages de point

Le nuage de points montre une tendance décroissante :
lorsque le PM2.5 augmente, le NDVI a tendance à diminuer.
Cela suggère une corrélation négative faible à modérée,
indiquant que les zones plus polluées sont généralement
moins végétalisées.

Vérification de la linéarité et de la normalité

Pour la linéarité (voir 3.Description bivariée)

Pour la normalité

shapiro.test(df$PM25_ugm3)

shapiro.test(df$NDVI)

D'apres le test de shapiro on a le p-value de

PM25_ugm3(0.00407) et le p-value de NDVI(0.0001336)

sont tous inferieures à 0.05.Donc la normalitr n'est pas

vérifiée.Danc ce cas on utiliser le Test de corrélation de spearman

Condition d'utilisation: on a deux variables

(PM25_ugm3 et NDVI) quantitatives ,les données

les données ne sont pas normalement distribuées,

la relation entre PM25_ugm3 et NDVI est monotone(non linéaire)

Donc on peut utiliser le Test de corrélation de spearman

4. Test de corrélation

cor.test(df$PM25_ugm3, df$NDVI, method="spearman")

D'aprés le Test de corrélation de spearman,

Le coefficient de corrélation entre le PM2.5 et le NDVI

est de -0.5821751, ce qui indique une corrélation négative

modérée entre PM25_ugm3 et NDVI

<u>Conclusion :</u>

La végétation, mesurée par le NDVI, est significativement

associée aux concentrations de PM2.5.

La corrélation négative (r = −0,5821751) indique que

le PM25_ugm3 et NDVI s'évaluent dans le sens contraire

c'est à dire ,si l'un augmente l'autre diminue

3.5) Quanti × Quali (2 groupes)

PM25_ugm3 ~ Brulage_dechets

1. Chargement des librairies

```
library(ggplot2)
df$Brulage_dechets <- as.factor(df$Brulage_dechets)
```

2. Description univariées des variables

Pour la variable qualitative 'Brulage_dechets'

```
Brulage_dechets_table <- table(df$Brulage_dechets)
Brulage_dechets_table
```

Répartition par Brulage de dechets

```
print(Brulage_dechets_table)
barplot(Brulage_dechets_table,
        main = "Distribution des Brulages de dechets",
        xlab = "Brulage de dechets",
        ylab = "Fréquence")
```

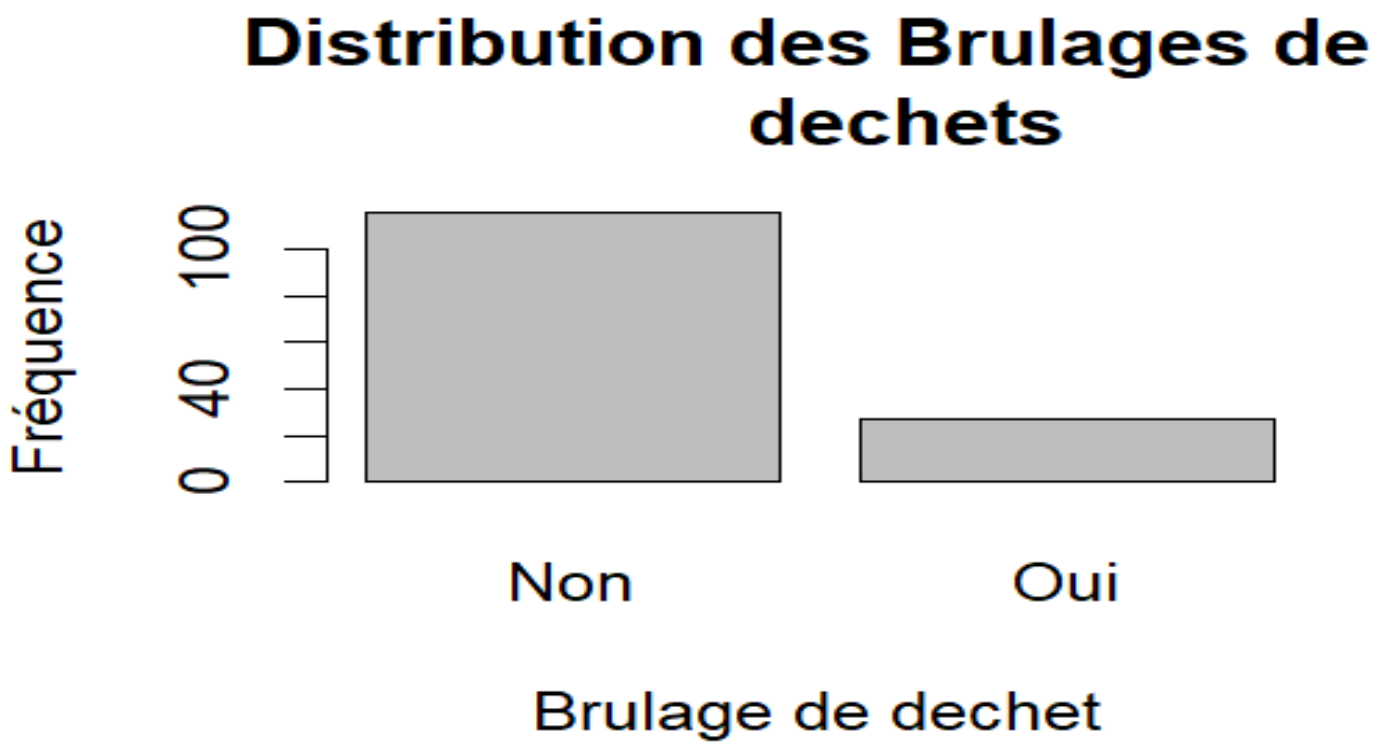

Commentaire de la Distribution des Brulages de dechets

On a plus de non brulage de dechets(116) que de brulage de dechets(27)

Distribution de la variable quantitative 'PM25_ugm3'

Summary(df$PM25_ugm3)

Interpretation du summary

5.566 reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inférieure ou égale à 24.122

75% des observations ont une valeur inférieure ou égale à 48.703

50% des observations ont une valeur inférieure ou égale à34.597

73.432 represente la valeur maximale observée(la plus grande)

la moyenne des observations de PM25_ugm3 est 36.628 .

Histogramme du PM25

```
ggplot(df, aes(x = PM25_ugm3)) +
  geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
  labs(title = "Distribution du PM25",
       x = "PM2.5 (µg/m³)",
       y = "Fréquence") +
  theme_minimal()
```

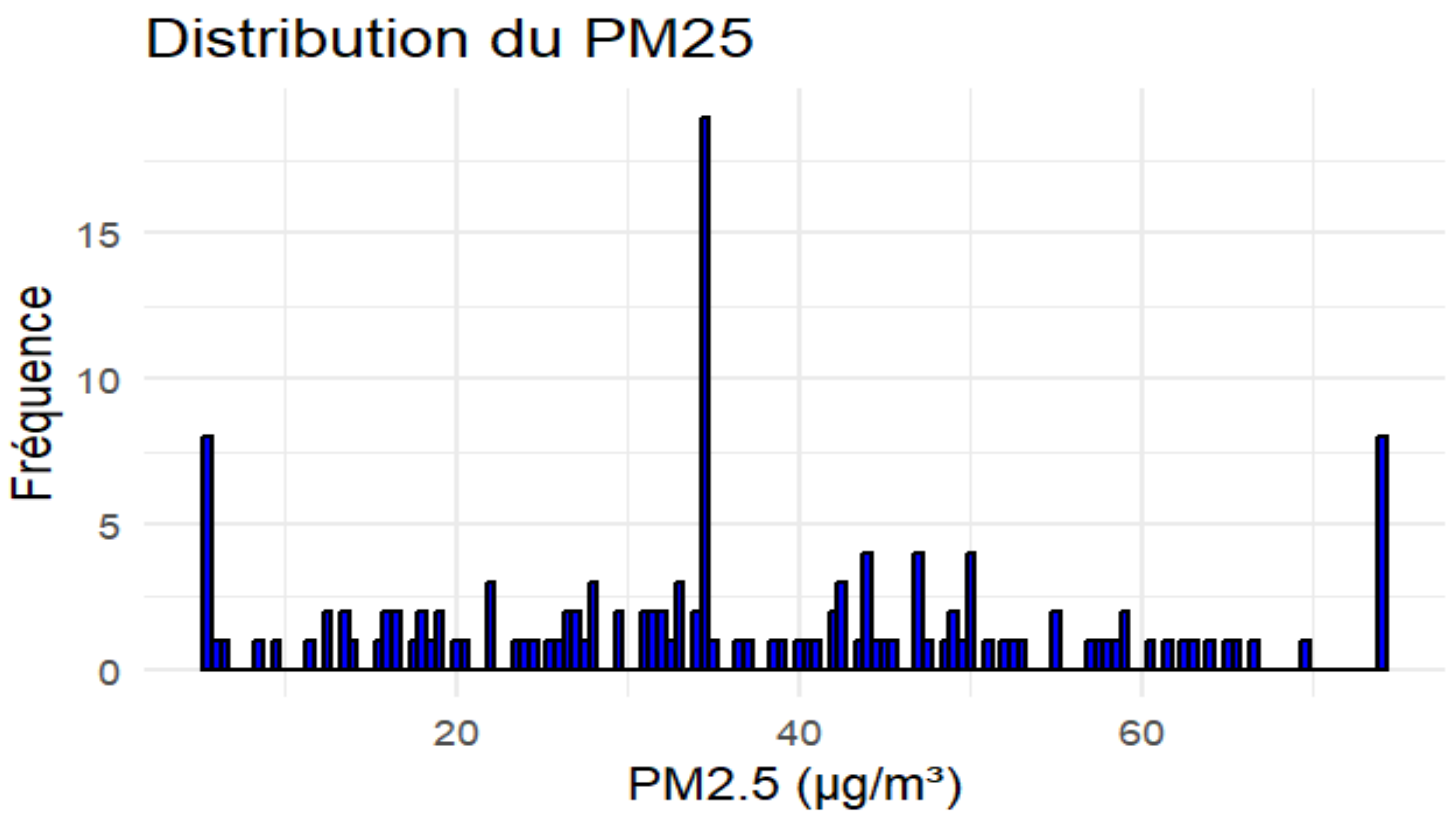

Commentaire du histogramme de la distribution du PM25

La distribution du PM2.5 est asymétrique à droite, avec une majorité de valeurs modérées et quelques concentrations élevées. Cette asymétrie suggère la présence de valeurs extrêmes, ce qui justifie l'usage de statistiques robustes (médiane, tests non paramétriques).

3. Description bivariée et formulation d'une hypothése

Boxplot PM25 par Brulage de dechet

```
ggplot(df, aes(x = Brulage_dechets, y = PM25_ugm3, fill = Brulage_dechets)) +
  geom_boxplot() +
  labs(title = "PM25 selon le Brulage de dechet", )
x = "Brulage de dechet"
y = "PM2.5 (µg/m³)" +
  theme_minimal()
```

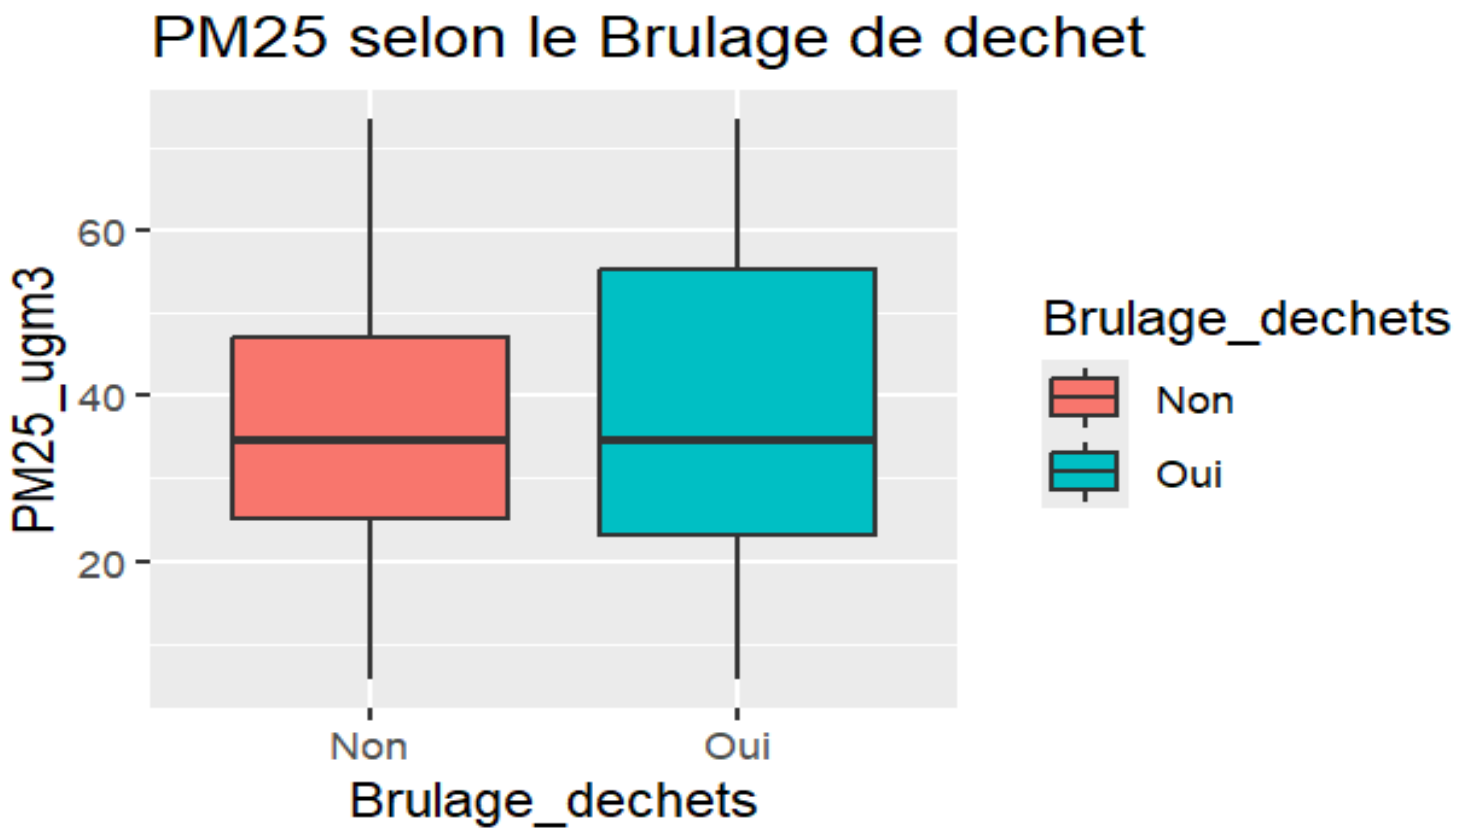

on constate que le PM25_ugm3 est plus important

quand il y'a Brulage de dechets

Donc il y'a liaison entre PM25_ugm3 et Brulage_dechets

4. Tests Statistiques

Vérification des hypothéses :

1) Normalité globale (ou par groupe si on veut étre plus strict)

Test de Shapiro-Wilk pour la variable 'PM25_ugm3'

H0 : normalité

H1 : pas de normalité

```
library(car)
shapiro_test_total <- shapiro.test(df$PM25_ugm3)
print(shapiro_test_total)
```

D’apres le test de shapiro,on p-value (0.00407)

inferieure à 0.05,donc on rejete H0 et on acepte H1

d'ou la normalite n'est pas vérifié.Donc on va utiliser

les test non parametriques

condition d'utilisation

Indépendance des échantillons

Pas de normalité

donc on peut utiliser le Test de Wilcoxon

Séparation des données par type de zone

```
temp_Oui <- df$PM25_ugm3[df$Brulage_dechets  == "Oui"]
temp_Non  <- df$PM25_ugm3[df$Brulage_dechets  == "Non"]
```

Test de Wilcoxon

```
wilcoxon_test <- wilcox.test(temp_Oui, temp_Non)
print(wilcoxon_test)
```

D'aprés le Test de Wilcoxon,le p-value (0.4713) est

superieure à 0.05. On rejette H1 et on acepte H0

Donc les ditributions des deux groupes sont égales

Conclusion :

le PM25 n'est pes différent quand il y'a Brulage (oui/non)

3.6) Quanti × Quali (2 groupes)

Bruit_dB ~ Industriel_oui_non

création de la colonne Industriel_oui_non à partir de Usage_sol

```
df$Industriel_oui_non <- ifelse(df$Usage_sol == "Industriel",
                "Oui", "Non")
table(df$Industriel_oui_non)
```

1. Chargement des librairies

```
library(ggplot2)
```

```
Non Oui
119  24
```

On a plus d’ Usage_sol sans Industrie(Non) que d’Usage_sol Industrie

```
df$Industriel_oui_non<- as.factor(df$Industriel_oui_non)
```

2. Description univariées des variables

Pour la variable qualitative 'Brulage_dechets'

```
Industriel_oui_non_table <- table(df$Industriel_oui_non)
Industriel_oui_non_table
```

Répartition par BIndustriel_oui_non

```
print(Industriel_oui_non_table)
barplot(Industriel_oui_non_table,
        main = "Distribution des Industriel_oui_non",
        xlab = "Industriel_oui_non",
```

ylab = "Fréquence")

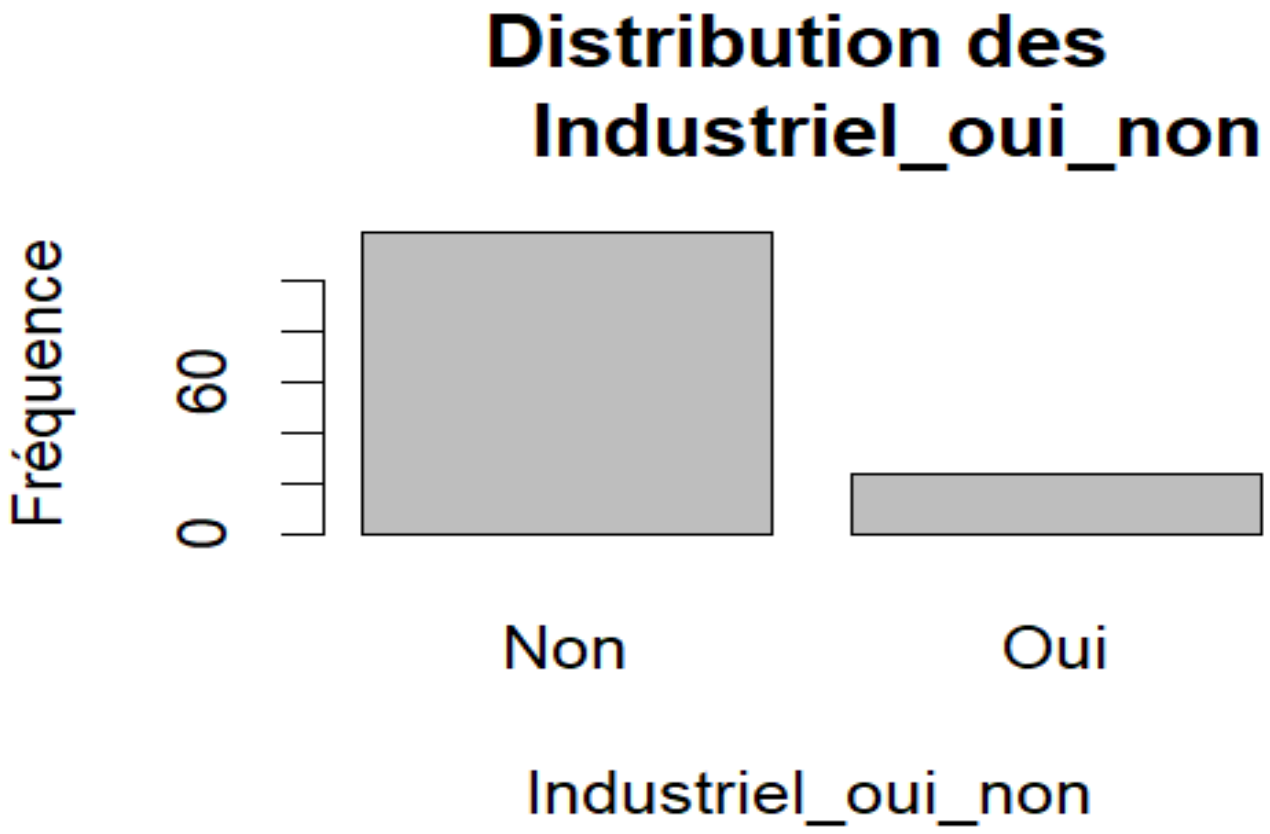

Commentaire de la Distribution des Industriel_oui_non

On a plus de Non industrie que d'industrie(Oui)

Distribution de la variable quantitative 'Bruit_dB'

summary(df$Bruit_dB)

interpretation du summary

44.68 reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inferieure ou égale à 55.33

75% des observations ont une valeur inferieure ou égale à 66.05

50% des observations ont une valeur inferieure ou égale à61.88

73.31 represente la valeur maximale observée(la plus grande)

la moyenne des observations du Bruit_dB est 60.69

Histogramme des Bruits

```
ggplot(df, aes(x = Bruit_dB)) +
  geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
  labs(title = "Distribution du Bruit",
       x = "Bruit (dB)",
       y = "Fréquence") +
  theme_minimal()
```

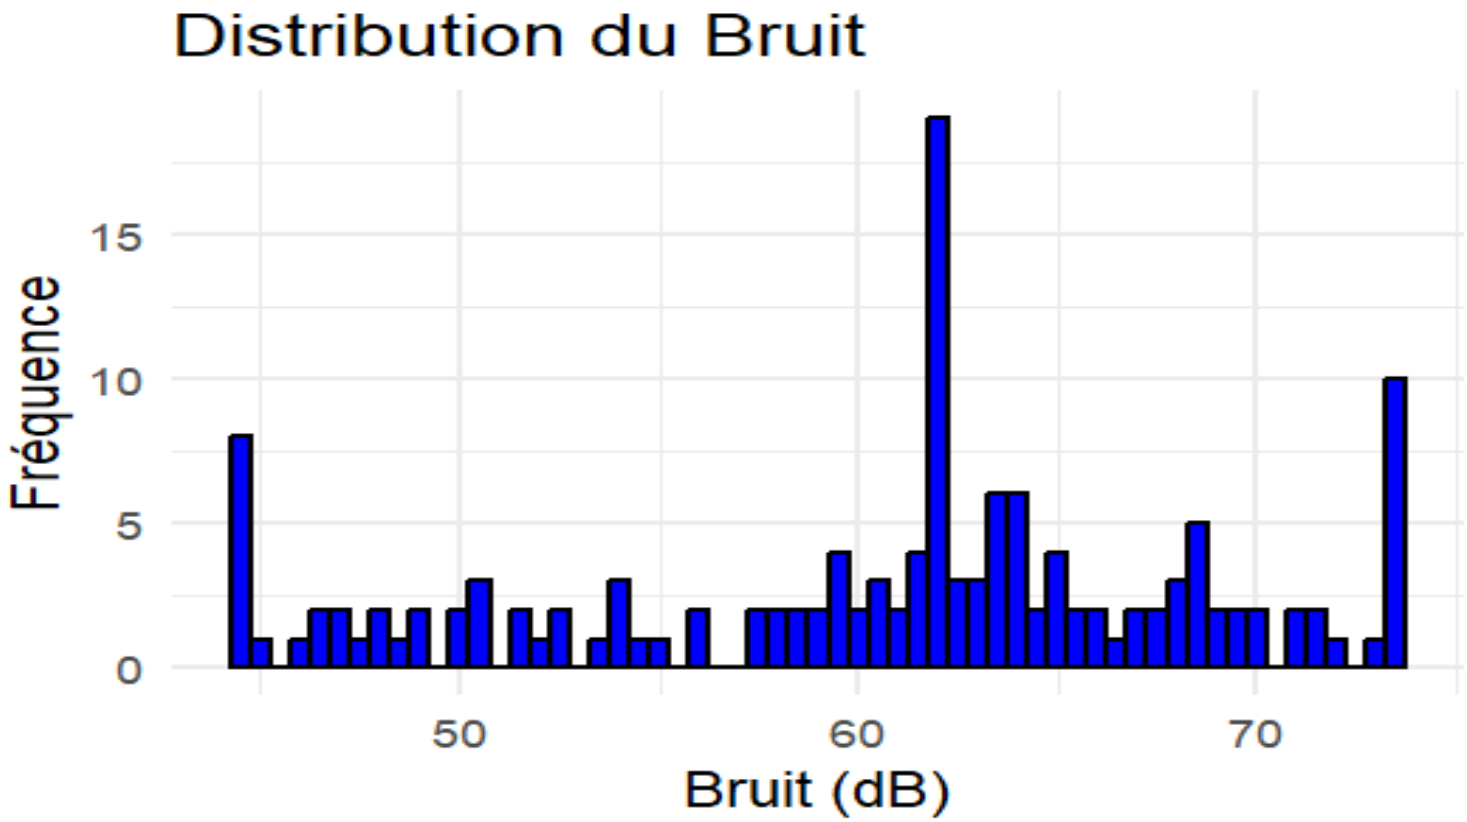

Interpretation du histogramme la Distribution du Brui

Le niveau sonore varie beaucoup sur ce site.

On observe plusieurs pics principaux :

.Un niveau calme autour de 50 dB.

.Des niveaux modérés à élevés vers 60 dB et plus.

.Des pics occasionnels au-delà de 65 dB.

Cela montre que le bruit n'est pas constant et provient probablement de différentes sources ou activités à différents moments.

3. Description bivariée et formulation d'une hypothése

Boxplot PM25 par Industriel

```
ggplot(df, aes(x = Industriel_oui_non, y = Bruit_dB, fill = Industriel_oui_non)) +
  geom_boxplot() +
  labs(title = "Bruit selon l' Industriel", )
x = "Industriel_oui_non"
y = "Bruit (dB)" +
  theme_minimal()
```

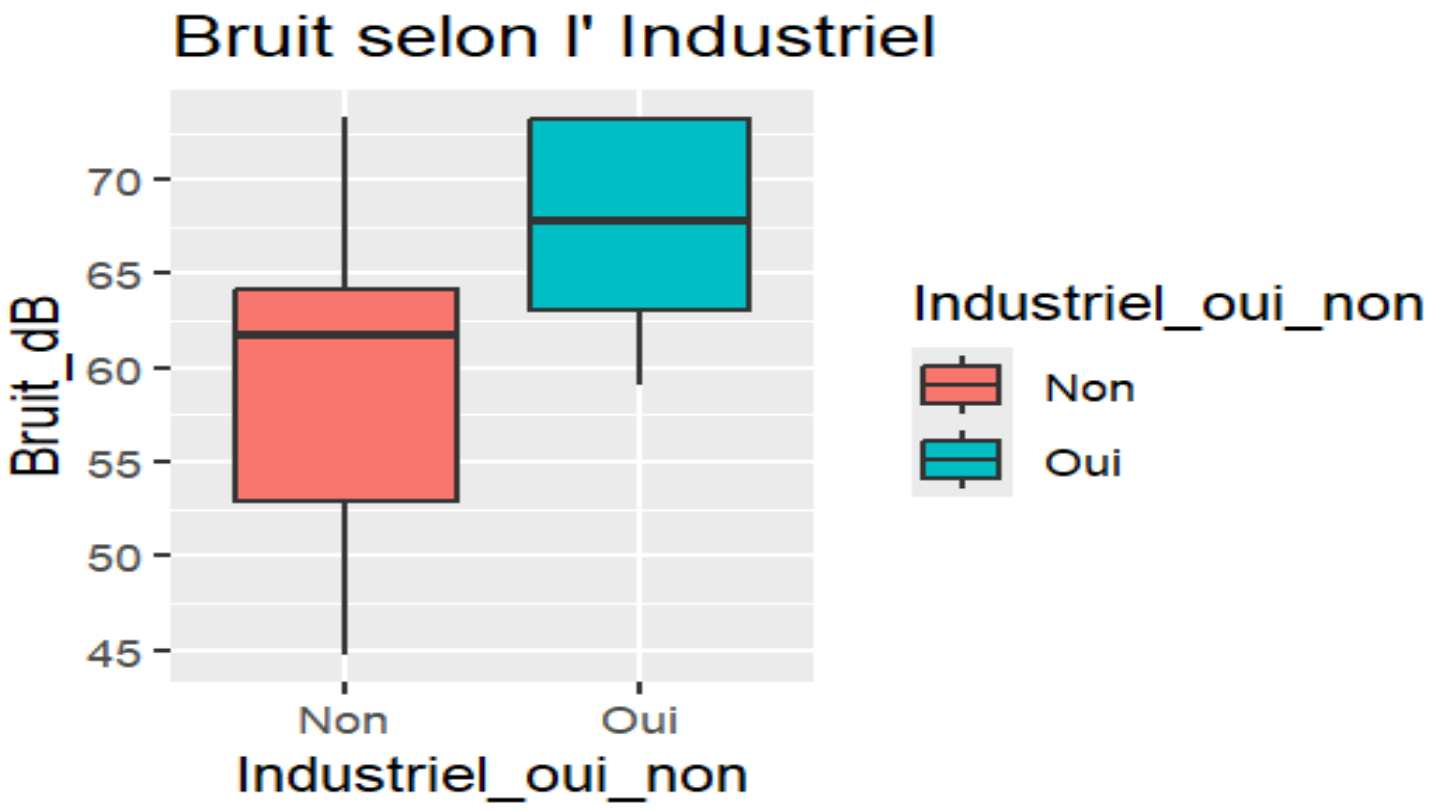

Commentaire du boxplot du Bruit selon l'industrie

Les zones industrielles sont beaucoup plus bruyantes que

les autres (65 dB contre 52 dB en moyenne).

Le bruit y est aussi plus variable, avec de nombreux pics

sonores élevés.Les zones sans industrie ont un

environnement sonore plus stable et modéré.

4. Tests Statistiques

Vérification des hypothéses :

1) Normalité globale (ou par groupe si on veut étre plus strict)

Test de Shapiro-Wilk pour la variable 'Bruit_dB'

H0 : normalité

H1 : pas de normalité

```
library(car)
shapiro_test_total <- shapiro.test(df$Bruit_dB)
print(shapiro_test_total)
```

d'apres le test de shapiro,on p-value(9.19e-06)

inferieure à 0.05,donc on rejete H0 et on acepte H1

d'ou la normalite n'est pas vérifié.Donc on va utiliser

les test non parametriques

Condition d'utilisation

Indépendance des échantillons

Pas de normalité

donc on peut utiliser le Test de Wilcoxon

Séparation des données par type de zone

```
Industriel_oui <- df$PM25_ugm3[df$Industriel_oui_non  == "Oui"]
```

```
Industriel_Non  <- df$PM25_ugm3[df$Industriel_oui_non  == "Non"]
```

Test de Wilcoxon pour deux échantillons indépendants

H0 : la médiane est la même dans les deux groupes

H1 : la médiane est différente dans les deux groupes

```
wilcoxon_test <- wilcox.test(Industriel_oui, Industriel_Non)
print(wilcoxon_test)
```

D'aprés le Test de Wilcoxon,le p-value (1.713e-05) est inferieure à 0.05. On rejette H0 et on acepte H1

Donc les ditributions des deux groupes sont diférentes

Conclusion :

bruit diffère selon le type de zone

3.7 Quanti × Quali (>2 groupes)

Bruit_dB ~ Type_zone

1. Description univariée

Classe_altitude

```
table_zone <- table(df$Type_zone)
print(table_zone)
table_zone <- table(df$Type_zone)
print(table_zone)
barplot(table_zone,
        main = "Répartition des Types de zone",
        xlab = "Types de zone",
        ylab = "Fréquence")
```

D'aprés le barplot,on constate que

la zone urbain est plus importante

suivie de la zone Périurbain

qui est aussi plus importante que

la zone Rural

Temperature_moy

summary(df$Bruit_dB)

interpretation du summary

44.71 reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inferieure ou égale à 55.33

75% des observations ont une valeur inferieure ou égale à 66.05

50% des observations ont une valeur inferieure ou égale à61.88

73.31 represente la valeur maximale observée(la plus grande)

la moyenne des observations du Bruit_dB est 60.69

```
hist(df$Bruit_dB,
     main = "Distribution du Bruit_dB",
     xlab = "Bruit (dB)",
     col = "skyblue",
     border = "black")
```

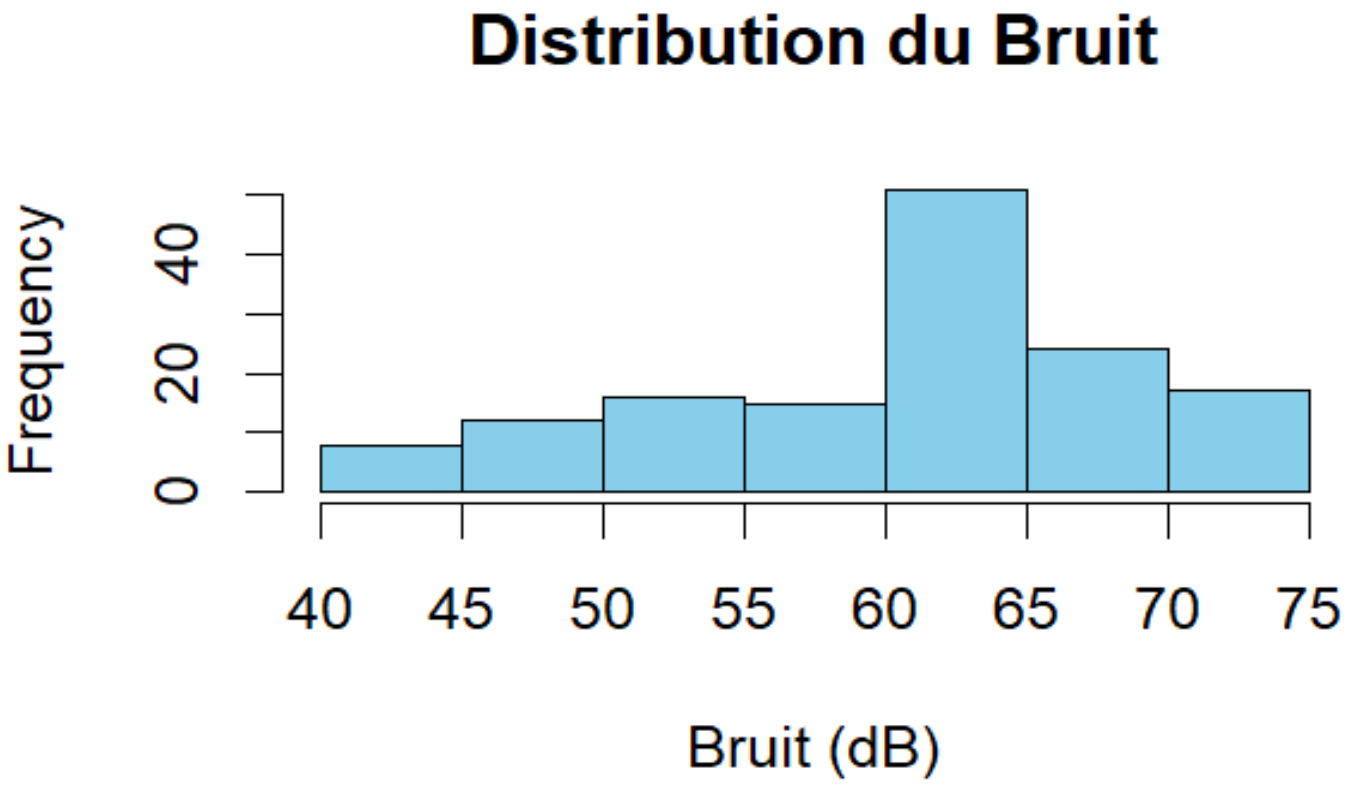

Commentaire de l'histogramme de Bruit_dB :

L'histogramme montre la distribution des concentrations

de NO2_ppb.La majorité des observations se situe entre

25-50dB,indiquant que que ces valeurs sont les plus fréquentes

On observe également des concentrations plus faibles

(inférieures à 20dB)mais elles sont moins représentées.

2.Description bivariée

Boxplot Température x Classe d'altitude

```
ggplot(df, aes(x = Type_zone, y = Bruit_dB, fill =Type_zone)) +
  geom_boxplot() +
  labs(title = "Bruit selon le Type_zone",
```

```
    x = "Type de zone",
    y = "Bruit (dB)") +
theme_minimal()
```

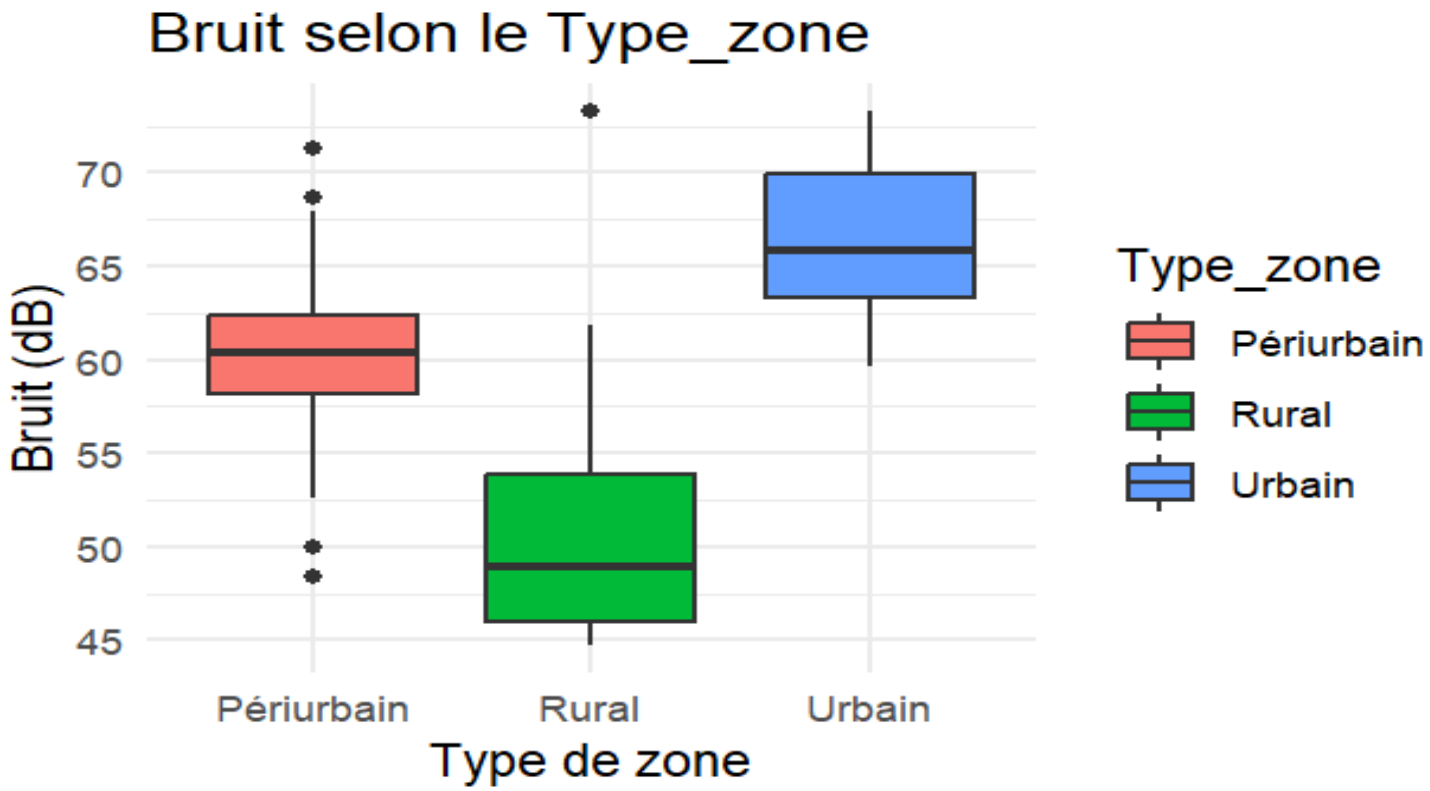

Interprétation du Boxplot du Bruit selon le Type_zone

Le bruit dépend fortement du type de zone.

Les zones urbaines sont les plus bruyantes.

Les zones périurbaines sont modérément bruyantes.

Les zones rurales sont les plus calmes.

En bref, plus la zone est urbanisée, plus le niveau sonore est élevé.

3. Tests statistiques

vérification de la normalité

shapiro.test(df$Bruit_dB)

d'apres le test de shapiro,on p-value(9.19e-06)

inferieure à 0.05,donc on rejete H0 et on acepte H1

d'où la normalite n'est pas vérifié.Donc on va utiliser

le Test de Kruskal-Wallis

Conditions d’utilisation:

Groupes indépendants

k = 3 groupes

Test de Kruskal-Wallis

```
kruskal_test <- kruskal.test(Bruit_dB ~ Type_zone, data = df)
print(kruskal_test)
```

D'aprés le Test de Kruskal-Wallis,on a le p-value(2.2e-16)

inferieure à 0.05 alors au moins un groupe

est différent des autres

Conclusion

le niveau Brut différe significativement selon le type de zone

3.8) Quanti × Quali (>2 groupes)

PM25_ugm3 ~ Usage_sol

1. Description univariée

Usage_sol

```
table_Usage <- table(df$Usage_sol)
print(table_Usage)
barplot(table_Usage,
        main = "Répartition des Usages de sol",
        xlab = "Usage de sol",
```

ylab = "Fréquence")

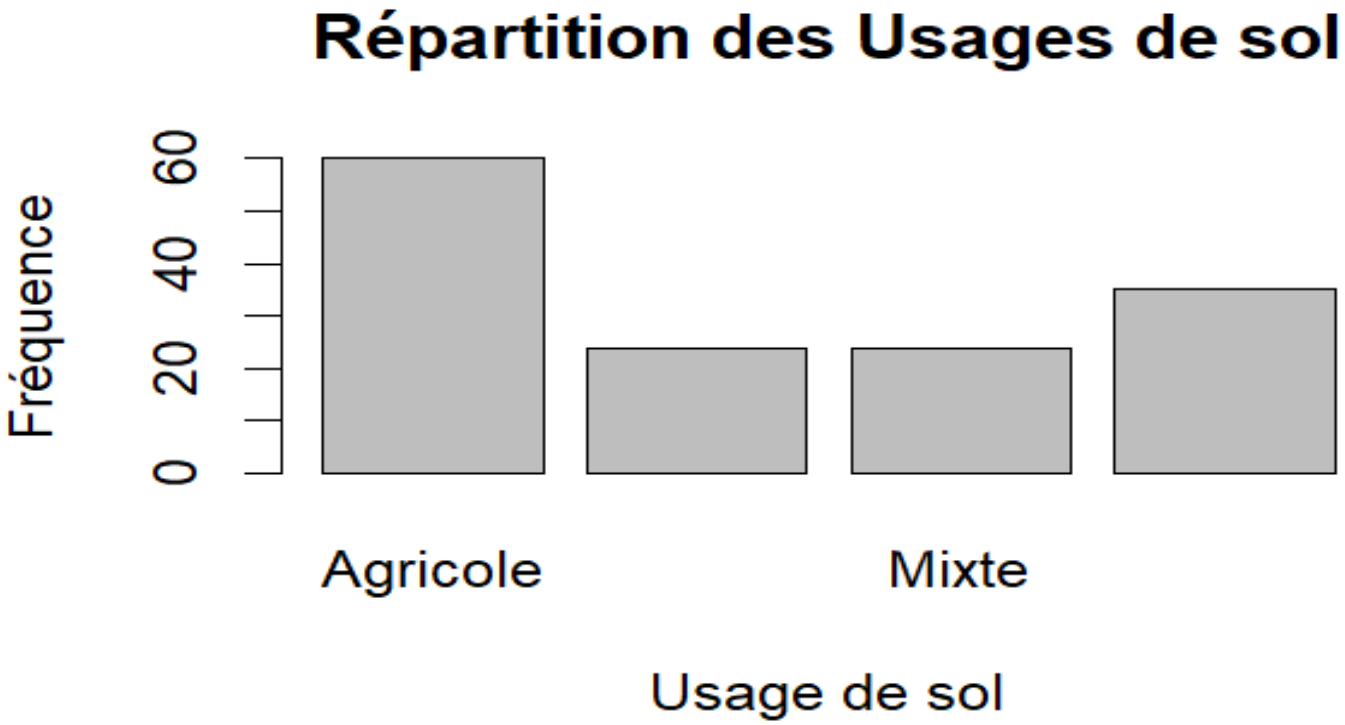

D'aprés le barplot,on constate que

l'Usage de sol Agricole(60) est plus important

suivi par l'Usage de sol Résidentiel(35)

suivi par les deux autres Usage de sol(Industiel et Mixte)

qui ont la même valeur(24)

PM25_ugm3

summary(df$PM25_ugm3)

Interpretation du summary

5.566 reprente la valeur minimale observée(la plus faible de l'echantillion)

25% des observations ont une valeur inférieure ou égale à 24.122

75% des observations ont une valeur inférieure ou égale à 48.703

50% des observations ont une valeur inférieure ou égale à34.597

74.063 represente la valeur maximale observée(la plus grande)

la moyenne des observations de PM25_ugm3 est 36.628

```
hist(df$PM25_ugm3,
     main = "Distribution de le PM2.5",
     xlab = "PM2.5 (µg/m³)",
     col = "skyblue",
     border = "black")
```

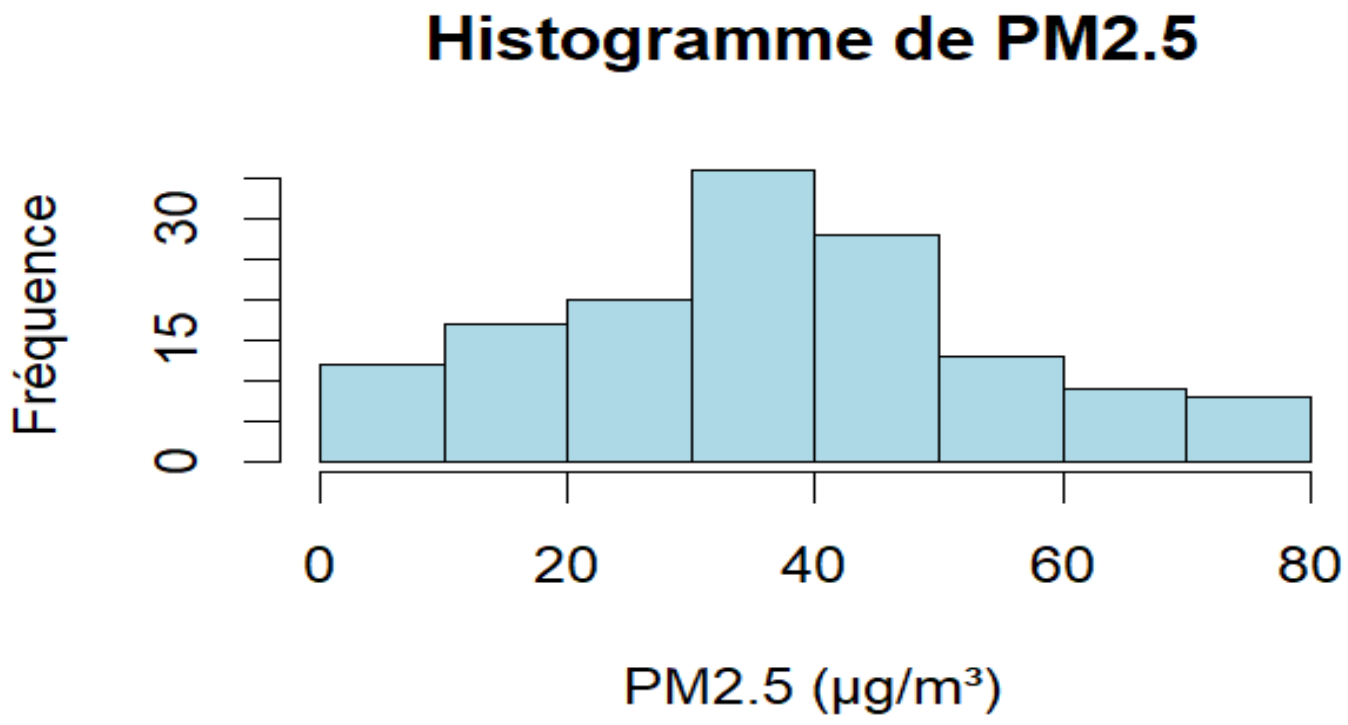

2.Description bivariée

Boxplot Température x Classe d'altitude

```
ggplot(df, aes(x = Usage_sol, y = PM25_ugm3, fill = Usage_sol)) +
  geom_boxplot() +
  labs(title = "PM2.5 selon l'Usage de sol",
       x = "Usage de sol",
       y = "PM2.5 (µg/m³)") +
  theme_minimal()
```

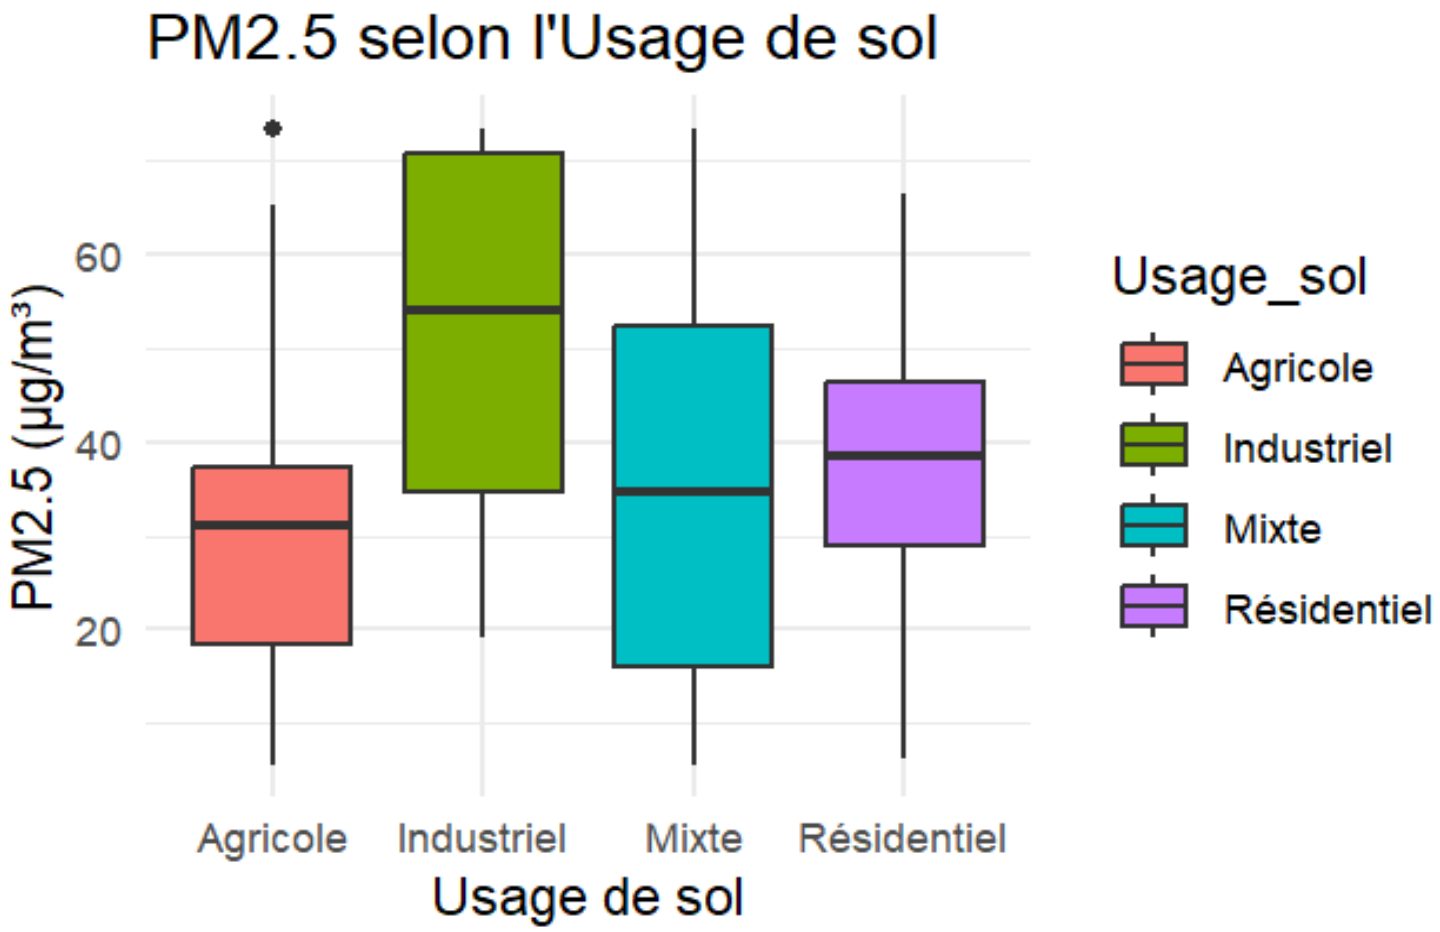

Commentaire du Boxplot du PM2.5 selon l'Usage de sol

L'usage du sol influence beaucoup la pollution PM2.5.

Les zones industrielles sont les plus polluées.

Les zones résidentielles le sont aussi, mais moins.

La végétation et les terres agricoles ont l'air le moins pollué.

En bref, plus une zone est urbanisée et industrialisée,

plus l'air y est chargé en particules fines.

3. Tests statistiques

vérification de la normalité

shapiro.test(df$PM25_ugm3)

d'apres le test de shapiro,on p-value(0.00407)

inferieure à 0.05,donc on rejete H0 et on acepte H1

d'ou la normalite n'est pas vérifié.Donc on va utiliser le Test de Kruskal-Wallis

Conditions d’utilisation:

Groupes indépendants

K(4) > 3 groupes

Test de Kruskal-Wallis

kruskal_test <- kruskal.test(PM25_ugm3 ~ Usage_sol, data = df)

print(kruskal_test)

D'aprés le Test de Kruskal-Wallis,on a le p-value(2.038e-05)

inferieure à 0.05 alors au moins un groupe est différent des autres

Conclusion

le PM2.5 différe significativement selon l'Usage du sol

3.9) Ordinale × Ordinale : Taux de Kendall (ou Spearman)

Perception_air_1a5 vs Gene_bruit_1a5

conditions d'application

on a deux variables ordinales

on a une relation monotone,c'est à dire,si l'une augmente

l'autre diminue (justifé par le test de Kendall)

Observations indépendantes entre les deux variables

```
df$Perception_air_1a5 <- factor(
df$Perception_air_1a5,
  levels =1:5,
  ordered = TRUE
)
df$Gene_bruit_1a5 <- factor(
  df$Gene_bruit_1a5,
  levels = 1:5,
  ordered = TRUE
)
Perc <- as.numeric(df$Perception_air_1a5)
Gen <- as.numeric(df$Gene_bruit_1a5)
df
kendall_test  <- cor.test(Perc , Gen, method = "kendall", use = "complete.obs")
print(kendall_test)
```

D'apres le kendall_test,on le p-value(0.0003081)

inférieure à 0.05,on rejette H0 et on acepte H1.Donc

il existe une association monotone entre Perception_air_1a5 et Gene_bruit_1a5

on a aussi la valeur de τ(-0.2709712),donc

on une association négative parfaite

Conclusion :

Donc on peut conclure que la Perception de la qualité de

est faiblement mais significaticement liée à la gène du Bruit

3.10)Données appariées : t apparié / Wilcoxon signé

Uniquement sur la campagne poussière (Campagne == "Campagne_poussiere") :

Filtrer les données pour la campagne "Campagne_poussiere"

```
library(dplyr)
library(ggplot2)
```

Campagne poussière

```
df_campagne <- df[df$Campagne == "Campagne_poussiere", ]
```

Valeurs Avant et Après

```
avant = df_campagne$PM25_ugm3[df_campagne$Phase_intervention == "Avant"]
apres = df_campagne$PM25_ugm3[df_campagne$Phase_intervention == "Après"]
```

Différences

```
difference = apres – avant
hist(difference,
     main = "Différence du PM2.5 (Après - Avant)\nCampagne poussière",
     xlab = "Différence PM2.5 (µg/m³)",
     col = "lightgray",
     border = "black")
abline(v = 0, lty = 2)
```

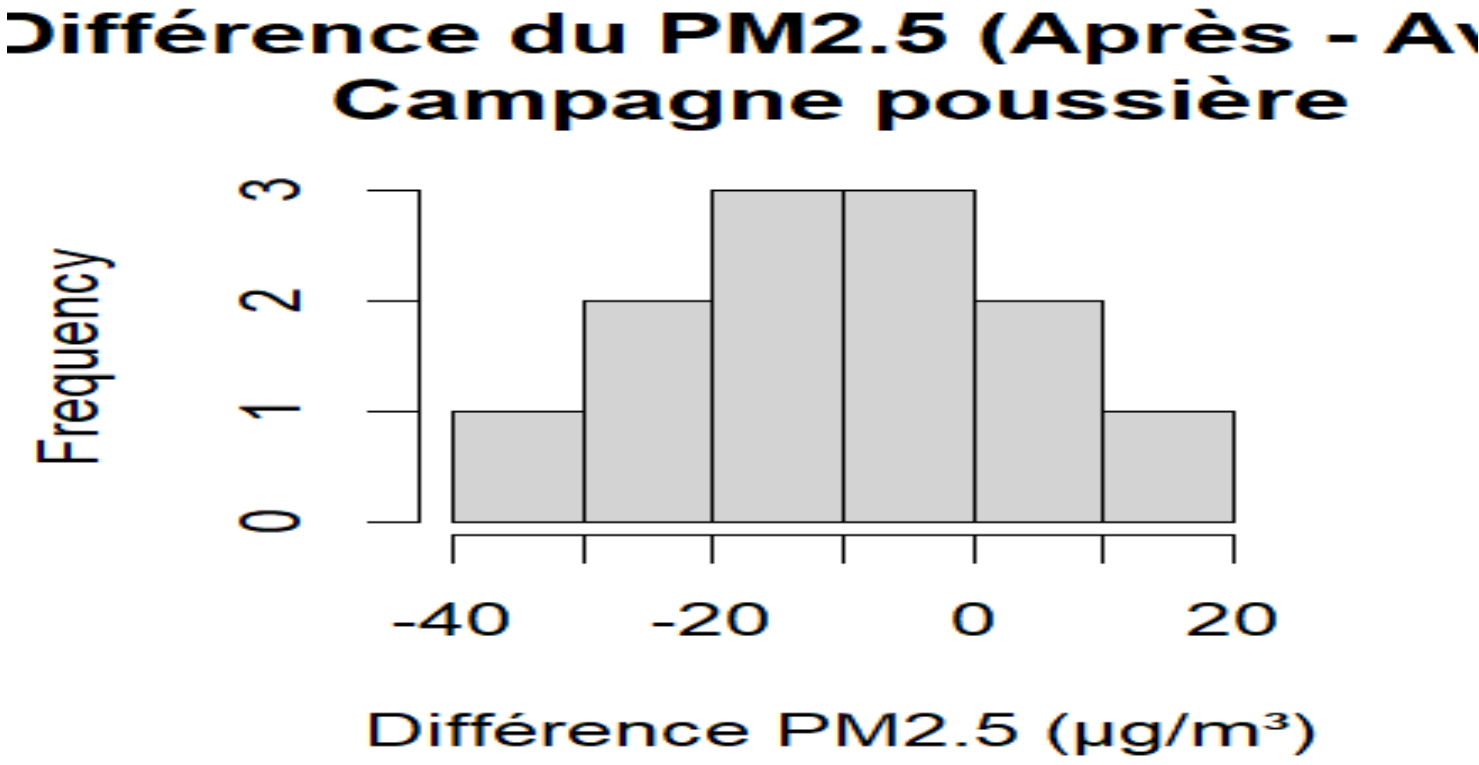

Commentaire du histogramme :

Les concentrations de PM2.5 sont globalement plus faibles après la campagne poussière qu'avant, comme l'indiquent les différences majoritairement négatives (Après − Avant). Cela suggère un effet réducteur de la campagne, bien que non homogène.

Verification de la normalite

H0:p_value < = 0.05: normalité rejetée

H1: p_value > 0.05: normalité plausible

shapiro.test(difference)

D'aprés shapiro.test ,on a la p_value(0.9261) est supérieure à 0.05 Donc il y'a normalité

On va utiliser les Test appariés

Test de student

H0: Les moyennes des deux groupes sont égales.

H1: Les moyennes des deux groupes sont différentes.

Conditions d’utilisation:

La variable quantitative est normalement distribuée dans chaque groupe.

Les observations sont indépendantes

```
test_final = t.test(apres, avant, data = df, paired = TRUE)
print(test_final)
```

#Interprétation:

D'prés le test de Student,on a p-value(0.04819) inférieure à 0.05, alors on accepte H1 et on rejette H0.Donc Les moyennes des deux groupes sont différentes

Conclusion :

La campagne a entaîné de réduction significative du PM2.5

CONCLUSION FINALE :

L’analyse montre une relation entre le PM2.5 et certaines variables environnementales, notamment une diminution du PM2.5 dans les zones plus végétalisées. Le bruit est plus élevé en zones industrielles. En revanche, la campagne poussière n’a pas entraîné de réduction significative du PM2.5.

RECOMMANDATION :

- Surveiller en priorité les zones industrielles.
- Renforcer la végétalisation urbaine.
- Lutter contre le brûlage des déchets.
- Améliorer et prolonger les campagnes de réduction delà pollution.